

IN1160, uke 4:

Klyngeanalyse

Erik Velldal

Språkteknologigruppen (LTG)
Seksjon for maskinlæring
Institutt for informatikk
Universitetet i Oslo

11. februar, 2026





- Evaluering av veiledet klassifikasjon
- Ikke-veiledet maskinlæring for å oppdage grupperinger i data: klyngeanalyse (*clustering*)
- *k*-Means og hierarkisk klyngeanalyse

- For å **evaluere** en klassifikator måler vi hvor mange korrekte prediksjoner den gjør for usette testeksempler.
- Hvorfor kan vi ikke teste på treningsdataene?
- De annoterte testdataene kalles gjerne for **gullstandarden**.
- Evaluerer ved å **sammenligne** modellens prediksjoner mot gullstandarden.
- Vi skal se på ulike **evalueringsmål**,
- samt ulike **datasplitter**.
- Hvorfor evaluere i det hele tatt?

- For å **evaluere** en klassifikator måler vi hvor mange korrekte prediksjoner den gjør for usette testeksempler.
- Hvorfor kan vi ikke teste på treningsdataene?
- De annoterte testdataene kalles gjerne for **gullstandarden**.
- Evaluerer ved å **sammenligne** modellens prediksjoner mot gullstandarden.
- Vi skal se på ulike **evalueringsmål**,
- samt ulike **datasplitter**.
- Hvorfor evaluere i det hele tatt?
 - Sammenlikne ulike modeller, ulike parametre, ulike treningsdata, osv.
 - Og for å finne ut hvor godt noe fungerer før det eventuelt tas i bruk i praksis.

Så på bruk av datasplitter forrige uke



Annotert datasett

Så på bruk av datasplitter forrige uke




Annotert datasett


Trening

Testing

Så på bruk av datasplitter forrige uke




Så på bruk av datasplitter forrige uke




Flyten i trening og anvendelse av en klassifikator



(a) Training




(b) Prediction




(Image: <https://www.nltk.org/book/ch06.html>)


Riktig og galt på ulike måter: feilmatriser




Riktig og galt på ulike måter: feilmatriser



Riktig og galt på ulike måter: feilmatriser



Riktig og galt på ulike måter: feilmatriser



prediksjon = positiv
prediksjon = negativ

gull = positiv

sann positiv (TP)


falsk negativ (FN)

gull = negativ

falsk positiv (FP)

sann negativ (TN)

Riktig og galt på ulike måter: feilmatriser



prediksjon = positiv
prediksjon = negativ

gull = positiv

sann positiv (TP)


falsk negativ (FN)

gull = negativ

falsk positiv (FP)

sann negativ (TN)

Riktig og galt på ulike måter: feilmatriser



prediksjon = positiv
prediksjon = negativ

gull = positiv

sann positiv (TP)


falsk negativ (FN)

gull = negativ

falsk positiv (FP)

sann negativ (TN)

Riktig og galt på ulike måter: feilmatriser



prediksjon = positiv
prediksjon = negativ

gull = positiv

sann positiv (TP)


falsk negativ (FN)

gull = negativ

falsk positiv (FP)

sann negativ (TN)

Riktig og galt på ulike måter: feilmatriser



prediksjon = positiv
prediksjon = negativ

gull = positiv

sann positiv (TP)


falsk negativ (FN)

gull = negativ

falsk positiv (FP)


sann negativ (TN)

Riktig og galt på ulike måter: feilmatriser



	gull = positiv	gull = negativ
prediksjon = positiv	sann positiv (TP)	falsk positiv (FP)
prediksjon = negativ	falsk negativ (FN)	sann negativ (TN)


Evalueringsmål



$$\text{Nøyaktighet} = \frac{TP+TN}{N}$$

	gull = positiv	gull = negativ
prediksjon = positiv	TP = 1	FP = 1
prediksjon = negativ	FN = 2	TN = 6


Evalueringsmål



$$\text{Nøyaktighet} = \frac{TP+TN}{N}$$
$$= \frac{1+6}{10} = 0.7$$

	gull = positiv	gull = negativ
prediksjon = positiv	TP = 1	FP = 1
prediksjon = negativ	FN = 2	TN = 6

Evalueringsmål




$$\text{Nøyaktighet} = \frac{TP+TN}{N}$$
$$= \frac{1+6}{10} = 0.7$$

$$\text{Presisjon} = \frac{TP}{TP+FP}$$

$$\text{Sensitivitet} = \frac{TP}{TP+FN}$$

	gull = positiv	gull = negativ
prediksjon = positiv	TP = 1	FP = 1
prediksjon = negativ	FN = 2	TN = 6

Evalueringsmål




$$\text{Nøyaktighet} = \frac{TP+TN}{N}$$
$$= \frac{1+6}{10} = 0.7$$

$$\text{Presisjon} = \frac{TP}{TP+FP}$$
$$= \frac{1}{1+1} = 0.5$$

$$\text{Sensitivitet} = \frac{TP}{TP+FN}$$

	gull = positiv	gull = negativ
prediksjon = positiv	TP = 1	FP = 1
prediksjon = negativ	FN = 2	TN = 6

Evalueringsmål




$$\text{Nøyaktighet} = \frac{TP+TN}{N}$$
$$= \frac{1+6}{10} = 0.7$$

$$\text{Presisjon} = \frac{TP}{TP+FP}$$
$$= \frac{1}{1+1} = 0.5$$

$$\text{Sensitivitet} = \frac{TP}{TP+FN}$$
$$= \frac{1}{1+2} = 0.33$$

	gull = positiv	gull = negativ
prediksjon = positiv	TP = 1	FP = 1
prediksjon = negativ	FN = 2	TN = 6

Evalueringsmål



$$\text{Nøyaktighet} = \frac{TP+TN}{N}$$
$$= \frac{1+6}{10} = 0.7$$

$$\text{Presisjon} = \frac{TP}{TP+FP}$$
$$= \frac{1}{1+1} = 0.5$$

$$\text{Sensitivitet} = \frac{TP}{TP+FN}$$
$$= \frac{1}{1+2} = 0.33$$

$$\text{F1-mål} = \frac{2 \times \text{presisjon} \times \text{sensitivitet}}{\text{presisjon} + \text{sensitivitet}}$$
$$= 0.4$$

	gull = positiv	gull = negativ
prediksjon = positiv	TP = 1	FP = 1
prediksjon = negativ	FN = 2	TN = 6

- **Nøyaktighet** (*accuracy*) = $\frac{TP+TN}{N} = \frac{TP+TN}{TP+TN+FP+FN}$
 - Andelen korrekte prediksjoner.
 - Ikke egnet for ubalanserte klasser (dvs. stor forskjell i antall positive / negative eksempler).
- **Presisjon** (*precision*) = $\frac{TP}{TP+FP}$
 - Andelen identifiserte klassemedlemmer som var korrekte.
- **Sensitivitet** (*recall*) = $\frac{TP}{TP+FN}$
 - Andelen faktiske klassemedlemmer som ble identifisert.
 - Avveining: Positive prediksjoner for alle eksempler vil gi sensitivitet på 100%, men typisk svært dårlig presisjon.
- **F1-mål** (*F1-score*) = $\frac{2 \times \text{presisjon} \times \text{sensitivitet}}{\text{presisjon} + \text{sensitivitet}}$
 - Balanserer presisjon og sensitivitet i ett mål.
- **Manuell feilanalyse** også alltid anbefalt!

Mikrogjennomsnitt (*micro-average*)

- Summør først TP, FP, TN og FN for alle eksempler på tvers av alle klasser, og beregn så globale metrikker basert på disse.
- **Store** klasser vil få mest inflytelse på **mikro**gjennomsnittet.

Mikrogjennomsnitt (*micro-average*)

- Summér først TP, FP, TN og FN for alle eksempler på tvers av alle klasser, og beregn så globale metrikker basert på disse.
- **Store** klasser vil få mest innflytelse på **mikro**gjennomsnittet.

Makrogjennomsnitt (*macro-average*)

- Beregn først metrikkene for hver enkelt klasse, og ta så det globale snittet av disse.
- **Små** klasser vil få mye innflytelse på **makro**gjennomsnittet.

Mikrogjennomsnitt (*micro-average*)

- Summér først TP, FP, TN og FN for alle eksempler på tvers av alle klasser, og beregn så globale metrikker basert på disse.
- **Store** klasser vil få mest innflytelse på **mikro**gjennomsnittet.

Makrogjennomsnitt (*macro-average*)

- Beregn først metrikkene for hver enkelt klasse, og ta så det globale snittet av disse.
- **Små** klasser vil få mye innflytelse på **makro**gjennomsnittet.

Vektet

- Som makro, men tar høyde for ubalanse mellom klassene.
- Bidraget fra hver klasse vektes utfra antall (gull-)eksempler.

Intrinsisk

- Fokus på modellens ytelse på oppgaven den ble trent for.
- Evaluering mot data annotert med samme type informasjon som i treningsdatatene.
- Altså hva vi har antatt så langt.
- F.eks., for temaklassifikasjon; hva er F1-målet på et reservert testsett med dokumenter annotert med de samme tematiske klassene?

Intrinsisk

- Fokus på modellens ytelse på oppgaven den ble trent for.
- Evaluering mot data annotert med samme type informasjon som i treningsdatatene.
- Altså hva vi har antatt så langt.
- F.eks., for temaklassifikasjon; hva er F1-målet på et reservert testsett med dokumenter annotert med de samme tematiske klassene?


Ekstrinsisk

- Fokus på prediksjonenes effekt i en større eller 'nedstrøms' oppgave, 'ende-til-ende'.
- F.eks., for temaklassifikasjon; hvordan påvirkes brukertilfredsheten i et system for innholdsanbefalinger som bruker prediksjonene som et av flere trekk?



(Vi kommer tilbake til begge flere ganger senere i semesteret!)

- **Veiledet** læring krever **annoterte** data.
- Både **kvalitet** og **volum** viktig for resultatene.
- Krever typisk manuell innsats og ekspertise: ofte svært **kostbart**.
- **Ikke-veiledet** læring kan enkelte ganger være et alternativ.






- **klynge**: 'gruppe med personer eller annet som befinner seg nær hverandre; samling'
 - Bokmålsordboka
- Jf. 'kontiguitetshypotesen'

- **klynge**: 'gruppe med personer eller annet som befinner seg nær hverandre; samling'
– Bokmålsordboka
- Jf. 'kontiguitetshypotesen'

Klyngeanalyse

- Ikke-veiledet læring fra uannoterte data
- Automatisk gruppering av objekter.
- Ingen forhåndsdefinerte klasser:
- Vi spesifiserer kun **trekkene** og **likhetsmålet**, og ofte antall klynger **k**.



Eksempler på anvendelser av klyngeanalyse



- Dimensjonsreduksjon (*dimensionality reduction*)
- Klassebaserte trekk for andre modeller
- Visualisering og utforskende dataanalyse (*EDA: exploratory data analysis*)

- **Dimensjonsreduksjon** (*dimensionality reduction*)
- **Klassebaserte trekk** for andre modeller
- **Visualisering** og **utforskende dataanalyse** (*EDA: exploratory data analysis*)

Noe eksempler for IR / NLP:

- F.eks. for å oppdage fremvoksende temaer i dokumentsamlinger; forskningslitteratur, sosiale medier, prosjektsøknader, feilmeldinger eller andre brukertilbakemeldinger ...

- **Dimensjonsreduksjon** (*dimensionality reduction*)
- **Klassebaserte trekk** for andre modeller
- **Visualisering** og **utforskende dataanalyse** (*EDA: exploratory data analysis*)

Noe eksempler for IR / NLP:

- F.eks. for å oppdage fremvoksende temaer i dokumentsamlinger; forskningslitteratur, sosiale medier, prosjektsøknader, feilmeldinger eller andre brukertilbakemeldinger ...
- Nyhetsaggregering

- **Dimensjonsreduksjon** (*dimensionality reduction*)
- **Klassebaserte trekk** for andre modeller
- **Visualisering** og **utforskende dataanalyse** (*EDA: exploratory data analysis*)

Noe eksempler for IR / NLP:

- F.eks. for å oppdage fremvoksende temaer i dokumentsamlinger; forskningslitteratur, sosiale medier, prosjektsøknader, feilmeldinger eller andre brukertilbakemeldinger ...
- Nyhetsaggregering
- Eksempler for søk;
- avgrense rangering av nærmeste naboer til nærmeste klynge.
- organiser søkeresultater i klynger i stedet for bare en liste.

Hierarkisk

- Lager en trestruktur av hierarkisk omsluttende klynger.
- Fungerer ved å iterativt enten
 - slå sammen klynger (nedenfra-og-opp) eller
 - splitte opp klynger (ovenfra-og-ned).

Flat

- Forsøker å direkte dele inn dataene i et sett av klynger.

- Gitt et sett av objekter $O = o_1, \dots, o_n$,
- konstruer et sett av klynger $C = c_1, \dots, c_k$,
- der hvert objekt o_i tilordnes en klynge c_j .
- = en partisjon.
- Parametere:
 - **Kardinaliteten** k (antall klynger).
 - **Likhetsfunksjonen** s .

- Gitt et sett av objekter $O = o_1, \dots, o_n$,
- konstruer et sett av klynger $C = c_1, \dots, c_k$,
- der hvert objekt o_i tilordnes en klynge c_j .
- = en partisjon.
- Parametere:
 - **Kardinaliteten** k (antall klynger).
 - **Likhetsfunksjonen** s .
- Formelt definert som et **optimaliseringsproblem**:
- Finn en tilordning $\gamma : O \rightarrow C$ som optimerer en **målfunksjon** (*objective function*) $F_s(\gamma)$.
- Generelt ønsker vi å optimalisere for;
 - høy intra-klynge likhet
 - lav inter-klynge likhet

- Det finnes et endelig antall mulige partisjoneringer av O .
- Naiv løsning: Enumerér alle mulige tilordninger $\Gamma = \{\gamma_1, \dots, \gamma_m\}$ og velg den beste;
- $\hat{\gamma} = \arg \min_{\gamma \in \Gamma} F_s(\gamma)$
- Problem: Eksponentielt mange mulige partisjoner.
- Kan **approximere** løsningen ved å **iterativt forbedre** en initiell partisjon.

- Den mest brukte varianten av flat klyngeanalyse.
- Deler de n observerte objektene inn i k klynger C slik at hvert punkt $\mathbf{x}_j$ tilordnes klyngen c_i med nærmest **sentroide** μ_i .
- Antar typisk euklidsk avstand som likhetsfunksjon s .


- Den mest brukte varianten av flat klyngeanalyse.
- Deler de n observerte objektene inn i k klynger C slik at hvert punkt $\mathbf{x}_j$ tilordnes klyngen c_i med nærmest **sentroide** μ_i .
- Antar typisk euklidsk avstand som likhetsfunksjon s .
- **Optimaliseringsproblemet**: minimér den **klyngeinterne kvadratsummen** (*within-cluster sum of squares*), $F_s = \text{WCSS}$:

$$\text{WCSS} = \sum_{c_i \in C} \sum_{\mathbf{x}_j \in c_i} \|\mathbf{x}_j - \mu_i\|^2$$


- Ekvivalent med å minimere den kvadrerte avstanden mellom objekter i samme klynge, og maksimere avstanden mellom punkter i ulike klynger.

- 1 **Initialisé**: Velg k tilfeldige startpunkter for sentroidene.
- 2 **Iterér**:
 - Hvert objekt tilordnes klyngen med nærmeste sentroide.
 - Beregn nye sentroider for klyngene.
- 3 **Terminér**: Når stoppekriteriet er oppfylt.
 - Kort sagt: Vi gjentar tilordningen av medlemskap og beregningen av sentroidene, helt til konfigurasjonen stabiliserer seg.


k -Means: eksempel for $k = 2$ i R^2 (Manning, Raghavan & Schütze 2008)



k -Means: eksempel for $k = 2$ i R^2 (Manning, Raghavan & Schütze 2008)




selection of seeds




assignment of documents (iter. 1)


k -Means: eksempel for $k = 2$ i R^2 (Manning, Raghavan & Schütze 2008)



selection of seeds




assignment of documents (iter. 1)




recomputation/movement of $\bar{\mu}$'s (iter. 1)


k-Means: eksempel for $k = 2$ i R^2 (Manning, Raghavan & Schütze 2008)




selection of seeds



assignment of documents (iter. 1)




recomputation/movement of $\bar{\mu}$'s (iter. 1)




$\bar{\mu}$'s after convergence (iter. 9)


k-Means: eksempel for $k = 2$ i R^2 (Manning, Raghavan & Schütze 2008)




selection of seeds




assignment of documents (iter. 1)



recomputation/movement of $\bar{\mu}$'s (iter. 1)



$\bar{\mu}$'s after convergence (iter. 9)



movement of $\bar{\mu}$'s in 9 iterations


Initialisering (*seeding*)

- Mange ulike heuristikker som kan brukes for å velge startpunktene:
 - velg k tilfeldige eksempler i datasettet;
 - velg k tilfeldige punkter i trekkrommet;
 - tilordne alle eksempler til k tilfeldige klynger og regn ut sentroidene; osv
- Initialiseringen kan ha stor betydning for klyngene vi ender opp med.

Eksempler på stoppekriterier

- Fast antall iterasjoner
- Klyngene eller sentroidene endrer seg ikke / lite mellom iterasjoner
- Terskel for reduksjon i målfunksjonen (absolutt eller relativ)

- WCSS er **monotont avtagende** (eller uendret) for hver iterasjon.
- Garantert å konvergere, men ikke nødvendigvis til det globale minimumet.
- Mulig løsning: evaluér for flere ulike tilfeldige initialiseringer;
- k -Means er **ikke-deterministisk**.



Fordeler

- Konseptuelt **enkel**, og lett å implementere.
- **Effektiv**. Typisk lineær i antall objekter.


Ulemper

- **Utliggere** (*outliers*) skape problemer.
- **Ikke-deterministisk** (ved tilfeldig initialisering).
- Antall klynger **k** må spesifiseres på forhånd.
- Mindre informativ enn de mer strukturerte klyngene fra hierarkiske metoder.

La oss nøste opp noen tråder...




- **Rocchio**-klassifisering kan sees som **1-nærmeste-nabo**-klassifisering mot sentroidene.
- Merk hvordan **k-Means**-klyngeanalyse kan sees som **Rocchio**-klassifisering i hver iterasjon.



La oss nøste opp noen tråder...



- **Rocchio**-klassifikasjon kan sees som **1-nærmeste-nabo**-klassifikasjon mot sentroidene.
- Merk hvordan **k-Means**-klyngeanalyse kan sees som **Rocchio**-klassifikasjon i hver iterasjon.




- *k*-Means arver dermed Rocchios innebygde **antakelser om klasseregioner**. (Hva var disse?)


Sammenslående (*agglomerative*) hierarkisk klyngeanalyse




- 1 La først hvert objekt utgjøre sin egen klynge;
 - 2 slå sammen de mest like klyngene etter tur,
 - 3 inntil alle objekter er i én og samme klynge.
- Hver sammenslåing definerer en **binær forgrening** i treet.



- Resultatet visualiseres ofte som en binær trestruktur kjent som et *dendrogram*.
- En sammenslåing vises som en horisontal linje som forbinder to klynger.
- y-koordinaten til linjen tilsvarer *likheten* mellom de sammenslåtte klyngene;
- *kombinasjonslikheten*.




- Resultatet visualiseres ofte som en binær trestruktur kjent som et *dendrogram*.
- En sammenslåing vises som en horisontal linje som forbinder to klynger.
- y-koordinaten til linjen tilsvarer *likheten* mellom de sammenslåtte klyngene;
- *kombinasjonslikheten*.
- *Hvordan måle likhet mellom klynger?*




- Så langt har vi sett hvordan vi kan beregne likhet mellom
 - par av objekter
 - objekter og klasser
- Nå: likhet mellom grupper / klynger
- Mål på **klyngelikhhet** blir gjerne omtalt som **koblingskriterier** (*linkage criteria*)
- Avgjør hvilket par av klynger som slås sammen i hvert steg;
- ulike kriterier vil gi en ulik sekvens av sammenslåinger.


Enkelkobling (Single-link)




Enkelkobling (Single-link)




Komplettkobling (Complete-link)




Enkelkobling (Single-link)




Komplettkobling (Complete-link)




Gjennomsnittskobling (Average-link)




Enkelkobling (Single-link)




Komplettkobling (Complete-link)




Gjennomsnittskobling (Average-link)




Sentroidekobling (Centroid-link)




Enkelkobling (Single-link)




Komplettkobling (Complete-link)



Gjennomsnittskobling (Average-link)




Sentroidekobling (Centroid-link)




- Alle koblingskriteriene kan beregnes på grunnlag av objektlikheter.
- Inndata er derfor typisk en **nærhetsmatrise** (*proximity matrix*) som beregnes på forhånd.


- Slår sammen de to klyngene med *minst avstand* mellom et gitt par av medlemmer.
- 'Nærmeste naboer'.
- Kan ha en uønsket kjedingseffekt: tendens til å produsere 'langstrakte' klynger.




- Slå sammen klyngene der den *største avstanden* mellom et gitt par av medlemmer er minst.
- 'Fjerneste naboer'
- Tilsvarende å velge sammenslåingene som vil ha minst diameter.
- Gir preferanse for kompakte klynger.
- Følsom for utliggere (*outliers*).



- AKA *group-average linkage*
- Slår sammen klyngene med *høyest gjennomsnittlig parvis likhet* i unionen.
- Antas gjerne som beste **standardvalg** for koblingskriterium.





- Likheten mellom klyngene c_i og c_j defineres som likheten mellom deres sentroider μ_i og μ_j .



- Likheten mellom klyngene c_i og c_j defineres som likheten mellom deres sentroider μ_i og μ_j .
- Ekvivalent med den gjennomsnittlige parvise likheten mellom objekter fra de *ulike* klyngene:


$$\text{sim}(c_i, c_j) = \mu_i \cdot \mu_j = \frac{1}{|c_i||c_j|} \sum_{x \in c_i} \sum_{y \in c_j} x \cdot y$$




- Likheten mellom klyngene c_i og c_j defineres som likheten mellom deres sentroider μ_i og μ_j .
- Ekvivalent med den gjennomsnittlige parvise likheten mellom objekter fra de ulike klyngene:

$$\text{sim}(c_i, c_j) = \mu_i \cdot \mu_j = \frac{1}{|c_i||c_j|} \sum_{x \in c_i} \sum_{y \in c_j} x \cdot y$$


- Ikke-monoton, utsatt for inversjoner:




- En grunnleggende antakelse: mindre klynger er mer koherente enn større.
- Vi antar vanligvis at **kombinasjonslikheten** er **monotont avtagende** mellom iterasjoner.
- Holder for alle kriteriene unntatt sentroidekobling.



- Sentroidekobling er **ikke-monoton**.
- Kan oppstå såkalte **inversjoner**:
- Kombinasjonslikheten for klynger kan øke gjennom sekvensen av sammenslåinger.
- Gir kryssende linjer i dendrogrammet:
- En horisontal linje som ligger lavere enn linjen for en tidligere sammenslåing.



- Treet representerer **flere partisjoner**:
- én for hvert nivå.
- Hvis vi ønsker **én flat partisjonering** må vi **beskjære** treet.
- Et **kuttekriterium** kan defineres ved en terskel for f.eks. kombinasjonslikhet (relativt fall eller absolutt), antall rotnoder, osv.



- Genererer treet **ovenfra-og-ned**:
 - 1** La først alle objekter være medlemmer av én og samme klynge;
 - 2** del deretter opp i mindre og mest mulig ulike klynger,
 - 3** helt til hvert objekt utgjør sin egen klynge med kun ett element (*singleton cluster*), eller et annet stoppekriterium oppfylles.

- Genererer treet **ovenfra-og-ned**:
 - 1** La først alle objekter være medlemmer av én og samme klynge;
 - 2** del deretter opp i mindre og mest mulig ulike klynger,
 - 3** helt til hvert objekt utgjør sin egen klynge med kun ett element (*singleton cluster*), eller et annet stoppekriterium oppfylles.
- I hver iterasjon kan man bruke en flat klyngeanalyse som f.eks. **k-Means**.

Med gullstandard

- Gjør klyngeanalyse av objekter i et annotert testsett og sammenlikn.
- Det finnes flere mål som fokuserer på den **interne kvaliteten** til klyngene, f.eks. 'renhet' (*purity*), som måler i hvilken grad klynger hovedsakelig inneholder objekter fra én enkelt klasse.

Med gullstandard

- Gjør klyngeanalyse av objekter i et annotert testsett og sammenlikn.
- Det finnes flere mål som fokuserer på den **interne kvaliteten** til klyngene, f.eks. 'renhet' (*purity*), som måler i hvilken grad klynger hovedsakelig inneholder objekter fra én enkelt klasse.

Uten gullstandard

- Flere mål som tar sikte på å vurdere kvaliteten på en partisjonering.
- F.eks. 'silhuettkoeffisienten' (*silhouette coefficient*), som måler hvor likt hvert objekt er sin egen klynge (kohesjon) sammenlignet med andre klynger (separasjon).
- Men verdiene er ofte avhengige av det konkrete datasettet og vanskelige å tolke.

- Undersøk om klyngeanalysen forbedrer resultatene i en nedstrøms oppgave.
- F.eks.: for ulike versjoner av et anbefalingssystem, der tematiske klynger brukes som trekk, kan man måle
 - brukertilfredshet
 - hvor mange anbefalte artikler brukerne leser eller klikker på
 - forbedring i salg
 - osv
- Generelt: klyngeanalyse er notorisk vrient å evaluere på en god måte.

Hvorfor bruker vi ikke alltid klyngeanalyse fremfor klassifikasjon?



- Oppgave: Sorter Lego-brikkene i grupper etter likhet!
- Hva er kriteriene? Farge? Fasong? Størrelse? Funksjon? Hvor mange grupper?
- Mister kontroll og tolkbarhet. Hva representerer grupperingen?

