

Det matematisk-naturvitenskapelige fakultet
Institutt for informatikk (IFI)

Generativ KI

Lilja Øvrelid
Språkteknologigruppen (LTG)

IN1160 - Introduksjon til
maskinlæring (Vår 2026)



UNIVERSITETET
I OSLO




Generativ KI

“The science and engineering of making intelligent machines.”

(McCarthy, 1956)

- Metoder: Regelbaserte vs **datadrevne**
- I dagens KI-landskap er KI stort sett ensbetydende med **generativ KI**




(<https://medium.com/uxdworld/what-is-generative-ai-c187659e9459>)

Så langt i kurset


- **Diskriminative** modeller:

- Lærer beslutningsgrense mellom klasser
- Klassifisering, f.eks. logistisk regresjon, nevrale nettverk




Generativ KI


- ML-modeller som skaper nytt innhold fra eksisterende data (tekst, bilder, lyd, video)
- **Generative** modeller:
 - Lærer mønstre i den underliggende datadistribusjonen for å skape nye, lignende data
 - Generering, f.eks. RNN, Diffusjonsmodeller og Transformer



Tekstgenerering




- **2019:** GPT-2
- **2020:** GPT-3
- **2022:** OpenAI slipper ChatGPT
- Siden har modellandskapet eksplodert



(<https://x.com/EconomyApp/status/1622029832099082241/photo/1>)


Bildegenerering

- Ved bruk av dyp læring
- **Diffusjonsmodeller**
 - Starter med støy
 - Lærer å gradvis fjerne støy
 - DALL-E, Midjourney, Stable Diffusion



Kodegenerering

- Kode som språk
- Store språkmodeller trent på kode:
 - Naturlig språk -> kode
 - Kodeutfylling (“code completion”)
- Copilot, Claude code, OpenCode



Forelesningen i dag

Dyp læring

- selv-veiledet læring

Transformer-arkitekturen



- forenklet introduksjon

Store språkmodeller

- Trening
- Evaluering
- Landskapet av språkmodeller


Pensum i dag

- Shah, kap 10: “Deep Learning” (utvalgte deler)
- Jurafsky & Martin:
 - Kapittel 7 om LLMer (utvalgte deler)
 - Kapittel 8 om Transformer-arkitekturen (utvalgte deler)




Dyp læring

- Nevrale nettverk med flere skjulte lag (derav “dyp”)
- En revolusjon innen ML fra ca 2012
- Startet med maskinsyn
- Muliggjort av:
 - maskinvare (“hardware”)
 - store mengder data
 - algoritmer/arkitekturer



Dyp læring

- Hva skal input til de dype, nevrale nettene bestå av?
- Tidligere:
 - manuelt definerte **trekk**
 - f.eks. personopplysninger (alder, vekt osv), ordene i en epost, farger/kanter i bilder osv.
- Dype, nevrale nett **lærer trekkene selv**
- Viste seg å være ekstremt nyttig, gitt tilgang på store mengder ustrukturerte data



(<https://builtin.com/machine-learning/deep-learning>)


Nevrale arkitekturer

Mange ulike arkitekturer med ulike bruksområder:

- Convolutional Neural Networks (CNNer)
 - Bildeklassifikasjon, bildesegmentering
- Recurrent Neural Networks (RNNer)
 - Sekvenser (tekst, tale, tidsserier)
- Generative Adversarial Networks (GAN)
 - Bildegenerering, kunstgenerering
- **Transformer**
 - ★ Tema i dag!

Selv-veiledet læring (“self-supervised learning”)


- Lærer fra store mengder **uannoterte** data uten manuell annotasjon
- Hvordan?
- Transformerer de opprinnelige dataene
 - Bilde: rotasjon, endre farger, osv
 - Tekst: maskere ut ord
- Lærer representasjoner som kan **gjenbrukes**



(<https://amitniss.com/posts/self-supervised-learning>)

Selv-veiledet læring


- Ga opphav til en ny arbeidsflyt i ML
- Grunntrening av modell på store mengder data ved bruk av selv-veiledet læring
 - Kunnskap
 - Generalisering
- Finjustering av modellen til spesifikk bruk



(<https://www.geeksforgeeks.org/machine-learning/self-supervised-learning-ssl/>)

Embedding

- Vektorrepresentasjoner av data (tekst, bilder, lyd)
- Tidligere: telle-baserte vektorer (ord/dokumenter)
- Embedding:
 - lavdimensjonale
 - tette ("dense")
 - distribuerte



word2vec (2013)

- Metode for å lære ordembeddinger
- Fanger **betydningen** til ord
- Selv-veiledet læring
- Klassifisere i stedet for å telle


“Jeg spiste til middag”



word2vec (2013)

- I stedet for å telle hvor ofte hvert ord w forekommer i konteksten
- Trener vi en klassifikator som skal predikere kontekstord, gitt målord $w(t)$
 - binær klassifikasjon
 - er w et sannsynlig kontekstord for ..?

Vi bryr oss ikke så mye om selve klassifiseringsoppgaven, men representasjonene (vektene) som læres



ResNet (2015)

- Dyp CNN-modell (100-1000 lag)
- Grunntrent modell som kan finjusteres til ulike bildeklassifiseringsoppgaver
- Trent ved veiledet klassifikasjon
- Stort bildedatasett: ImageNet



Transformer-arkitekturen

- Grunnlaget for alle store språkmodeller
- Dypt nevnt nettverk som er basert på såkalt **oppmerksomhet** “attention” (2019)

Attention Is All You Need

Ashish Vaswani*
Google Brain
avaswani@google.com

Noam Shazeer*
Google Brain
noam@google.com

Niki Parmar*
Google Research
nikip@google.com


Jakob Uszkoreit*
Google Research
usz@google.com

Llion Jones*
Google Research
llion@google.com

Aidan N. Gomez* †
University of Toronto
aidan@cs.toronto.edu

Łukasz Kaiser*
Google Brain
lukaszkaiser@google.com

Illia Polosukhin* ‡
illia.polosukhin@gmail.com




Transformer-arkitekturen

- Dominerer språkteknologi fullstendig
- Også brukt til generering:
 - Kode
 - Bilder
 - Audio
 - Video
 - Proteinstrukturer

Text				Code			
5 days ago							
Rank	Model	Score	Votes	Rank	Model	Score	Votes
1	Al claude-opus-4-6	1504	9,170	1	Al claude-opus-4-6-thinking		
2	Al claude-opus-4-6-thinking	1502	8,313	2	Al claude-opus-4-6		
3	G gemini-3.1-pro-preview	1500	4,041	3	Al claude-sonnet-4-6		
4	xI grok-4.20-beta1	1491	5,280	4	Al claude-opus-4-5-20251101-...		
5	G gemini-3-pro	1485	39,923	5	Al claude-opus-4-5-20251101		
6	G gpt-5.4-high	1479	3,503	6	G gpt-5.2-high		
7	G gpt-5.2-chat-latest-20260...	1479	5,786	7	G gemini-3.1-pro-preview		
8	G gemini-3-flash	1473	30,600	8	Z glm-5		
9	xI grok-4.1-thinking	1473	39,309	9	G gemini-3-pro		
10	Al claude-opus-4-5-20251101-...	1470	32,516	10	G gemini-3-flash		
View all				View all			

(<https://arena.ai/leaderboard>)


Transformer-arkitekturen



Tokenisering

Teksten segmenteres til **tokens** (ord/delord) og mappes til en **vektor**:

- initialiseres vilkårlig
- læres sammen med nettverket (tilbakepropagering)
- tokens som ofte forekommer sammen vil få lignende vektorrepresentasjoner



Ferdigtraint modell fryser de lærte vektorene (embeddings)

Oppmerksomhet (“attention”): motivasjon

Tidligere vektorrepresentasjoner: **statiske**

- Vil være helt lik for alle kontekster
- Gjenspeiler ikke konteksten et spesifikt ord forekommer i

The chicken didn't cross the road because **it** was too tired.

Hva betyr “it” her? Og hva vil en statisk embedding gi oss?


Kontekstuelle embeddinger

- Ordrepresentasjoner bør påvirkes av konteksten
 - The chicken didn't cross the road because **it** was too tired
 - The chicken didn't cross the road because **it** was too wide
- **Kontekstuelle embeddinger:** ord representeres ved vektorer som endrer seg avhengig av konteksten
- **Oppmerksomhet:** metode for å beregne kontekstuelle embeddinger

Oppmerksomhet

- Den kontekstuelle embeddingen for et ord beregnes ved å ta inn informasjon fra de andre ordene i konteksten
- Noen ord får mer oppmerksomhet enn andre
- Oppdaterer med informasjon fra ord i tidligere lag


columns corresponding to input tokens




Oppmerksomhet

- Formelt: vektet sum av vektorer
- Representasjonen til en embedding vektes med **likheten** til hvert av de foregående ordene
- Semantisk likhet beregnes ved **prikproduktet** mellom vektorene

columns corresponding to input tokens



Oppmerksomhet: forenklet



$$a_i = \sum_{j \leq i} \alpha_{ij} x_j$$

Flere detaljer kommer
i senere kurs!

Transformeren som språkmodell

Hva er en språkmodell?

- En ML-modell som predikerer ord

Det var en gang en ...

gutt


** hus*

bil

** selskap*

prinsesse

** spiste*



Hva er den mest sannsynlige
fortsettelsen av sekvensen?

Hvorfor ordprediksjon?

- Språkmodeller er ikke noen ny oppfinnelse
- Utstrakt bruk f.eks. i:
 - Talegjenkjenning
 - $P(\text{recognize speech}) > P(\text{wreck a nice beach})$
 - Maskinoversettelse
 - Mer sannsynlige sekvenser er ofte bedre oversettelser
 - $P(\text{She walked home}) > P(\text{She walked house})$
 - Auto-fullføring
 - Det er ikke lov å nyte medbrakt... ??




Hvorfor ordprediksjon?

Det er sånn **store språkmodeller (LLMer)** fungerer!

LLMer trenes til å predikere neste ord i en sekvens


LLMer **genererer** tekst ved å predikere ord

- predikerer neste ord igjen og igjen og igjen..



Språkmodellhodet

- Tar utdata fra siste transformerlag
- Bruker det til å predikere neste ord
- Gir oss en sannsynlighetsdistribusjon over alle ord i vokabularet
- **Sampler** fra sannsynlighetsdistribusjonen over V for å generere neste ord



Store språkmodeller (LLMer)

- (Large Language Models = LLMs)
- Motoren i dagens KI-systemer
- Chatbot'er som kan interagere med mennesker ved bruk av naturlig språk
- Brukes til rekke ulike oppgaver
- Grunnleggende: nevrale språkmodeller (transformer-modeller)




Store språkmodeller (LLMer)

- I dag skal vi se nærmere på:
 - Hva er en språkmodell?
 - Trening
 - Evaluering
 - Landskapet av språkmodeller


Overgripende arkitektur

Arkitekturer for LLMer




Dekoder

GPT, Claude, Llama,
Mistral



Enkoder

BERT-modellene




Enkoder-dekoder

Flan-T5, Whisper


Hva er en stor språkmodell?

- Et nevralt nettverk med
 - **Inndata:** kontekst av foregående ord
 - **Utdata:** sannsynlighetsdistribusjon over mulige ord



Kan generere


- Genererer ved gjentatt **sampling** fra sannsynlighetsdistribusjonen



I praksis velger vi ikke alltid det mest sannsynlige neste ordet!

Sentral innsikt

- Mange ulike oppgaver kan løses ved ordprediksjon!
- Gitt en inputtekst, en såkalt **prompt**
 - Generer modellen et svar, ord for ord
 - Betinget på prompt og foregående ord i svaret
- Modellen genererer ved å
 - Beregne sannsynligheten for neste ord, gitt kontekst $P(w_i | w_{<i})$
 - Sampler fra distribusjonen



Mange ulike oppgaver løses ved ordprediksjon!

Eksempeloppgave: Sentimentanalyse: "I like Jackie Chan" -> {positiv, negativ}

1. Inndata til språkmodellen: The sentiment of the sentence "I like Jackie Chan" is:
2. Og velger det mest sannsynlige neste ordet

Sentiment som betinget generering



Hvilket ord er mest sannsynlig?

$P(\text{positive} \mid \text{The sentiment of the sentence «I like Jackie Chan» is:})$

$P(\text{negative} \mid \text{The sentiment of the sentence «I like Jackie Chan» is:})$

Spørsmål-svar som generering

- Spørsmål “Who wrote the Origin of the Species?”

1. Input til språkmodellen:

- Q: Who wrote the book “the Origin of the Species”? A:

2. Generere videre betinget på prompt'et:



Prompt

Prompt: tekststreng som beskriver hvilken output brukeren ønsker fra språkmodellen

Flere former:

- Et spørsmål:
 - What is a transformer network?
- Strukturert
 - Q: What is a transformer network? A:
- Instruksjon
 - Translate the following sentence into Norwegian: "Chop the garlic finely."

Prompt med eksempler

The following are multiple choice questions about high school computer science.

Let $x = 1$. What is $x \ll 3$ in Python 3?

(A) 1 (B) 3 (C) 8 (D) 16

Answer: C

Which is the largest asymptotically?


(A) $O(1)$ (B) $O(n)$ (C) $O(n^2)$ (D) $O(\log(n))$

Answer: C

What is the output of the statement “a” + “ab” in Python 3?

(A) Error (B) aab (C) ab (D) a ab

Answer:




Kontekstlæring (“in-context learning”)

Trening av store språkmodeller

- **Trening:** gradvis justering av vektene til modellen slik at prediksjonene kommer nærmere gullstandard (treningsdata)
 - Moderne LLMer har milliarder av vekter som skal justeres
 - Svært ressurskrevende
 - Trening gjøres på spesialisert **maskinvare** (GPUer)
 - Flere steg med trening



Trening av store språkmodeller



Grunntrening (“pre-training”)

Mål: språkmodell med kunnskap om språk og verden

Hvordan?

LLMen trenes til predikere neste ord!

1. Ta et tekstkorpus

2. For hvert steg t

A. Be modellen predikere neste ord

B. Tren modellen ved bruk av gradientnedstigning til å minimere feilprediksjon

Selv-veiledet fordi bruker neste ord som klasse

1

Pretraining

Dataset:
100B to >5T tokens


Task: Next-token
prediction on
unlabeled texts

Output: base model /
“foundation model”

Project Gutenberg (PG) is a volunteer effort to digitize and archive cultural works, as well as to "encourage the creation and distribution of eBooks." It was founded in 1971 by American writer Michael S. Hart and is the oldest digital  library. Most of the items in its collection are the full texts of books or individual stories in the public domain. All files can be accessed for free under an open format layout, available on almost any computer. As of 3 October 2015, Project Gutenberg had reached 50,000 items in its collection of free eBooks.


(<https://magazine.sebastianraschka.com/p/llm-training-rlhf-and-its-alternatives>)

Grunntreningsdata



(Illustrasjon fra BabyLM shared task)

Grunntreningsdata



Datasettet "The Pile"

Instruksjonsjustering

Mål: modell som kan følge instruksjoner (praterobot)

Hvordan?

- Veiledet finjustering (“supervised fine-tuning”) av den grunntrente modellen
- Trenes på par av instruksjon og svar, ordprediksjon
- Krever menneske-produserte data

2

Supervised finetuning

More **next-token prediction**


Usually 1k-50k instruction-response pairs

```
{  
  "instruction": "Write a limerick about a  
    pelican.",  
  "input": "",  
  "output": "There once was a pelican so fine,  
    \nHis beak was as colorful as  
    sunshine,\nHe would fish all day,\nIn  
    a very unique way,\nThis pelican was  
    truly divine!\n\n",  
},  
  
{  
  "instruction": "Identify the odd one out from  
    the group.",  
  "input": "Carrot, Apple, Banana, Grape",  
  "output": "Carrot\n",  
},
```

(<https://magazine.sebastianraschka.com/p/llm-training-rlhf-and-its-alternatives>)

Preferansejustering (“preference alignment”)


- **Mål:** modell som er tilpasset brukerpreferanser
 - Ikke gjør skade
- **Hvordan?**
 - **Forsterkende læring** med menneskelig tilbakemelding (“Reinforcement Learning from Human Feedback”)
 - Belønningsmodell trenes på menneskelige preferanser



<https://pub.towardsai.net/rhf-the-engine-tuning-human-values-into-large-language-models-9c4bfd75fc79>

Evaluering av språkmodeller

- Essensiell del av språkmodellutvikling og forskning
- **Systematisk, reproduserbar og objektiv** evaluering
- Hvordan kan vi sammenligne LLMer?
- Ulike kriterier
 - **Ytelse/nøyaktighet**
 - Effektivitet
 - Sikkerhet



Evaluering av generering

- Hvorfor er dette vanskelig?
- I motsetning til de andre delene i kurset så har vi her ikke alltid noen absolutt gullstandard
- Mange mulige riktige svar!
- Samtidig trenger vi automatisert evaluering

▪ Q: *Hvorfor feirer nordmenn 17. mai?*



A: Nordmenn feirer at grunnloven ble signert på Eidsvoll i 1814.



A: 17 mai er nasjonaldagen vår og vi feirer opprettelsen av grunnloven vår.



A: 17. mai er Sveriges nasjonaldag og da feirer vi at vi fikk vår egen grunnlov

Evaluering: klassifikasjon

- Omformer generering til **klassifikasjon**, f.eks. i et spørsmål-svar oppsett
- Klarer modellen å generere riktig svar?
- Trenger da en tilgang til gullstandard
- **Fordel:** kan bruke tradisjonelle mål som nøyaktighet, F1
- **Ulempe:** ?



- *Hva er 17. mai for nordmenn?*
A: Det er nasjonaldagen
- B: Det er midtsommer
- C: Det er den store vaffeldagen

Evaluerings: generering

- Automatiske mål som ser på overlapp av ord eller sekvenser av ord
 - ROUGE
- Begrenset til ordform
- Tar ikke høyde for andre typer feil (fakta, grammatikk osv.)



A: 17 mai er vår nasjonaldag og vi feirer opprettelsen av grunnloven vår.




A: 17. mai er Sveriges nasjonaldag og då firar vi at vi fikk grunnloven vår

A: 17. Mai feirer Norge at vi fikk grunnloven vår

LLM-som-dommer

- Evaluering bør se på flere **kriterier**:
 - Relevans (bruker)
 - Naturlighet (flyt)
 - Sannferdighet (fakta)
 - Sikkerhet (skade)
- Ideelt sett: menneskelig evaluering, men dette er svært ressurskrevende
- Mer vanlig: **LLM-som-dommer**



(<https://memo.d.foundation/llm/llm-as-a-judge>)

Benchmarking

- Hva er et benchmark?
 - En samling evalueringsdatasett, evalueringsmål og en aggregeringsmetode
 - Utstrakt bruk av **ledertavler** der språkmodeller sammenlignes og rangeres på tvers av ulike oppgaver
 - Inneholder også ofte en sammenligning med menneskelig ytelse

Rank	Name	Score	Task ₁ (Acc.)	Task ₂ (F1)	Task ₃ (F1)
1	Model _A	0.95	0.98	0.92	0.96
2	Human	0.94	0.98	0.93	0.91
3	Model _B	0.90	0.95	0.95	0.80

Fiktiv ledertavle.

Benchmark oppgaver

- Kunnskap
 - Verdenskunnskap
 - Mer spesialisert (kultur/domene-spesifikk)
- Språkforståelse
- Tekstgenerering
- Rettferdighet/Sannferdighet

Instruction following 👉

- **Instruction:** Skriv dette som et eventyr!
- **Context:** Opplysningstiden var en samfunnskritisk åndsretning i Europa på 1700-tallet (fra 1688 til 1789) som uttrykte en tro på alle menneskers evner og fremmet renessansens humanistiske idealer...
- **Human response:** Det var en gang i Europa for mange hundre år siden et kongerike med all makt...


Norwegian-specific & world knowledge 🌐

- **Question:** "Æ træng læsta: Læsta er kjekt å ha. I alle fall sånn innimellom. Men hva er det for noe?"
- **Option A:** "Venner"
- **Option B:** "Lesestoff"
- **Option C:** "Ro"
- **Option D:** "Ullsokker"

(Eksempler fra NorEval)

Språkmodeller: størrelse

- Antall **parametre** i modellene:
 - Embedding-laget
 - Transformer-blokkene (oppmerksomhet)
 - Språkmodell-hodet (hidden x vokab)
- Store språkmodeller: milliarder av parametre
 - “Små” modeller: 7-13 milliarder
- Økning i størrelse (i antall parametre) har vist seg å ha klar sammenheng med bedre ytelse i en rekke ulike oppgaver

UNIVERSITETET
I OSLO


(<https://labelyourdata.com/articles/llm-fine-tuning/llm-model-size>)

Åpne vs lukkede modeller

- **Lukkede**/kommersielle modeller
 - Kun tilgjengelig via nettgrensesnitt
 - Lite informasjon om trening, data osv
 - Eks.: GPT-5, Claude, Grok
- **Åpne** modeller:
 - Tilgjengelig vektor (kan lastes ned og videretrenes)
 - Åpen kildekode
 - Transparens rundt treningsdata

Artificial Analysis Openness Index: Results


Openness Index assesses model openness on a 0 to 100 normalized scale (higher is more open)



(<https://artificialanalysis.ai/evaluations/artificial-analysis-openness-index>)

Åpne vs lukkede modeller

- Åpne modeller har begynt å ta igjen de lukkede
- “Et globalt kappløp”:
 - Kina har kommet sterkt i senere tid
 - Europa kommer (sakte) etter
- Hva med Norge?
 - Forskning på norske språkmodeller her ved IFI
 - NorMistral og NorOLMO




Hallusinerer

- LLMer trenes til å gi overbevisende svar
 - Neste-ord-prediksjon trent på store mengder data
 - Post-trening: hjelpsom, støttende osv.
- I utgangspunktet ingen kobling til verden eller begrep om “sannhet”
- **Hallusinerer**: usann informasjon i utdata fra LLM

RAG

- (= Retrieval Augmented Generation)
- Metode for å redusere hallusinerer:
 - LLMen søker etter relevant informasjon (i en database eller på nett) før responsen genereres



Resonnerende modeller

- For å få bedre svar, kan vi også be modellen resonnerere i flere steg (såkalt “chain-of-thought”-resonnering) før den svarer
- **Resonnerende modeller** som DeepSeek-R1 eller OpenAIs GPT-5.4 trenes spesifikt til resonnering:
 - Matteproblemer/logikknøtter osv
 - LLMen trenes til å løse disse steg-for-steg



Oppsummering: Generativ KI

- Dyp læring
 - selv-veiledet læring fra store mengder ustrukturerte data
 - grunntrente modeller som kan gjenbrukes
- Transformer-arkitekturen
 - oppmerksomhet lar oss ta høyde for konteksten
- Store språkmodeller
 - mange oppgaver løses med én modell
 - trenes ved flere steg (grunntrening, instruksjons- og preferansejustering)
 - kunnskap om landskapet av modeller

Spørsmål?

