

IN1160, uke 2:

Trekk og vektorrom

Erik Velldal


Språkteknologigruppen (LTG)
Seksjon for maskinlæring
Institutt for informatikk
Universitetet i Oslo


28. januar, 2026



For de neste ukene:

- Hvordan kan vi representere data i en matematisk modell?
- Vektorrommodeller
- Skal se hvordan representasjonene kan brukes for ulike typer læring
- Modellering av likhet og grupperinger i data: Klassifikasjon og klyngeanalyse
- Relevante anvendelser innenfor NLP og informasjonsgjenfinning






For i dag:

- Vektorrommodeller
- Trekkvektorer
- Avstandsmål
- Eksempler: modellering av semantisk likhet mellom ord og mellom dokumenter

- Eksempel: klassifikasjon.
- Krever annoterte treningsdata.
- Forhåndsdefinerte eksempler på hva som skal læres.



- Eksempel: klyngeanalyse.
- Prøver å finne grupperinger uten å bli vist annoterte eksempler.





- I begge tilfeller fungerer algoritmen ved å sammenlikne likheten mellom ulike eksempler.
- Men hvordan måler vi **likhet**?
- Som mennesker vil vi vurdere ulike observerbare egenskaper, attributter, eller trekk.
 - Størrelse
 - Pels
 - Ører
 - Øyne
 - ...
- En maskin må bli servert **trekk** som kan hentes ut av bildefila (f.eks. fargeintensiteter i piksler).


- **Trekk**: egenskaper ved dataene som vi tenker kan være relevante for en gitt oppgave.
- Må være observerbare og målbare.
- Tilsvare *variabler* i statistisk terminologi.
- Kan være **kategoriske** eller **numeriske**.
- **Binære** kategoriske trekk kan representeres numerisk som 0 eller 1.

Trekk	Mulige verdier	Eksempel	Type
Yrke:	 /  /  / 	Baker	Kategorisk
Fagorganisert:	 / 	1	Binær
Høyde (cm)		174	Numerisk
Temperatur (C)		37.5	Numerisk


- Enkelte algoritmer kan jobbe med kategoriske trekk direkte,
- men de fleste krever **konvertering** til numerisk form.
- Et kategorisk trekk kan representeres som flere binære – ett for hver mulige verdi.

Trekk	Verdi
Politi	0
Kunstner	0
Kokk	1
Bonde	0
Fagorganisert	1
Høyde (cm)	174
Temperatur (C)	37.5


- Kan tenke på trekkene som et **koordinatsystem**.
- Hver trekktype er en **dimensjon** eller akse.




- Kan tenke på trekkene som et **koordinatsystem**.
- Hver trekktype er en **dimensjon** eller akse.
- Objektene vi ønsker å representere er **punkter**, posisjonert utfra trekkverdiene sine.
- Avstanden mellom punktene reflekterer hvor like objektene er.
- Punkter som er nærme hverandre kaller vi **naboer**.




- For $d = 1$ er eksemplene punkter på en linje.
- For $d = 2$ er eksemplene punkter i et plan.
- For $d = 3$ har vi et tredimensjonalt rom.
- For $d > 3$ blir det vanskelig å visualisere.
- Høydimensjonale representasjoner med tusenvis av trekk ikke uvanlig i ML.




- Tenk at vi skal beskrive og sammenlikne studenter som tar IN1160.
- Vi velger å fokusere på 3 egenskaper: Hvor mange timer i snitt de bruker per dag på; studier, trening, og fest.
- Tenk at vi har et koordinatsystem i 3 dimensjoner der
 - Høyde = studier
 - Dybde = trening
 - Bredde = fest
- Ulike studenter vil posisjoneres som ulike punkter i koordinatsystemet.
- Lik bruk av tid = mindre avstand.




- Tenk at vi skal beskrive og sammenlikne studenter som tar IN1160.
- Vi velger å fokusere på 3 egenskaper: Hvor mange timer i snitt de bruker per dag på; studier, trening, og fest.
- Tenk at vi har et koordinatsystem i 3 dimensjoner der
 - Høyde = studier
 - Dybde = trening
 - Bredde = fest
- Ulike studenter vil posisjoneres som ulike punkter i koordinatsystemet.
- Lik bruk av tid = mindre avstand.
- Hvor vil vi finne punktet som representerer en student som;
 - kun fester, men aldri studerer eller trener?
 - studerer og trener masse men aldri fester?
 - bruker like mye tid på hver aktivitet?




- Tenk at vi skal beskrive og sammenlikne studenter som tar IN1160.
- Vi velger å fokusere på 3 egenskaper: Hvor mange timer i snitt de bruker per dag på; studier, trening, og fest.
- Tenk at vi har et koordinatsystem i 3 dimensjoner der
 - Høyde = studier
 - Dybde = trening
 - Bredde = fest
- Ulike studenter vil posisjoneres som ulike punkter i koordinatsystemet.
- Lik bruk av tid = mindre avstand.
- Hvor vil vi finne punktet som representerer en student som;
 - kun fester, men aldri studerer eller trener?
 - studerer og trener masse men aldri fester?
 - bruker like mye tid på hver aktivitet?
- Kan legge til flere egenskaper; antall timer brukt på: jobb, matlaging, frivillig innsats, friluftsliv, musikk, ...
- Vanskelig å visualisere, men samme prinsipp.



- Mer generelt kan vi tenke på objektene som **vektorer**.
- Har retning og lengde.
- Notasjon: en trekkvektor v er en ordnet sekvens med d elementer, numerisk indeksert:
- $v = [v_1, v_2, \dots, v_d]$
- $v \in \mathbb{R}^d$




- Mer generelt kan vi tenke på objektene som **vektorer**.
- Har retning og lengde.
- Notasjon: en trekkvektor v er en ordnet sekvens med d elementer, numerisk indeksert:
- $v = [v_1, v_2, \dots, v_d]$
- $v \in \mathbb{R}^d$



- To vektorer: $\mathbf{v1} = [1, 8]$, $\mathbf{v2} = [5, 5]$
- I et 2-dimensjonalt rom, $\mathbb{R}^2$.
- I praksis bruker vi kun den 1. (positive) kvadranten.
- Antar implisitt origo som startpunkt.
- **Lengden** (normen) til en vektor er definert som:


$$\|\mathbf{v}\| = \sqrt{\sum_{i=1}^n \mathbf{v}_i^2} = \sqrt{\mathbf{v} \cdot \mathbf{v}}$$







- Har nå sett hvordan data kan representeres som trekkvektorer.
- Har sagt at likhet kan modelleres som nærhet / avstand i vektorrommet.
- Men hvordan?
- Flere muligheter. Vi skal se på et par av de aller vanligste.

- $d(\mathbf{a}, \mathbf{b}) = \sqrt{\sum_{i=1}^n (\mathbf{a}_i - \mathbf{b}_i)^2}$
- Intuitiv tolkning: Avstanden mellom to punkter tilsvarer lengden på den rette linjen som forbinder dem.
- Beregner lengden på vektoren som forbinder punktene.





- Et potensielt problem med euklidsk avstand er følsomhet for ekstreme verdier og **lengden** på vektorene




- For å redusere påvirkningen av lengde kan vi først **normalisere** alle vektorene slik at $\|x\| = 1$
- Kan gjøres ved å dele hver verdi på vektorens lengde: $x \frac{1}{\|x\|}$
- Vil si at alle vektorene peker på overflaten til den såkalte enhetssirkelen.

- Vi kan også måle kosinus-likhet fremfor euklidsk *avstand*.
- Funksjon av vinkelen mellom vektorene:

$$\cos(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|} = \frac{\sum_i a_i b_i}{\sqrt{\sum_i a_i^2} \sqrt{\sum_i b_i^2}}$$

- Fast intervall mellom 0 (for vinkelrette vektorer) og 1 (for vektorer som peker i samme retning).
- Inkluderer lengdenormalisering.



- For *normaliserte* vektorer kan kosinus reduseres til *prikkproduktet*:

$$\cos(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|} = \mathbf{a} \cdot \mathbf{b} = \sum_{i=1}^n a_i b_i$$

- Kan beregnes svært effektivt.
- For normaliserte vektorer gir kosinus og euklidsk avstand samme relative rangering av naborelasjoner!

- Vi skal se på to ulike eksempler på **representasjon av tekstlige data som vektorer**.
- **Eksempel 1:** ordvektorer og semantiske rom.
 - Skal se hvordan vi automatisk – kun basert på rå tekst som input – kan lage trekkvektorer for ord, der avstandene gjenspeiler meningslikhet.
 - Utgangspunktet for **innlevering 1a**.
- **Eksempel 2:** dokumentvektorer for informasjonsgjenfinning.
 - Skal se hvordan vi kan representere dokumenter og andre tekster som vektorer.
 - Nyttig for informasjonssøk, tekstklassifikasjon, m.m.
 - Utgangspunktet for **innlevering 1b**, utvidet med klassifikasjon fra uke 3.

Hva betyr 'retawerif'?



Hva betyr 'retawerif'?



Han hadde fortsatt **hodepine** etter å ha **drukket** for mange **shots** med **retawerif** på **festen kvelden** i forveien.

Hva betyr 'retawerif'?




Han hadde fortsatt **hodepine** etter å ha **drukket** for mange **shots** med **retawerif** på **festen kvelden** i forveien.

- Vi kan utlede betydningen fra konteksten.

- **Hypotesen**: Ord som forekommer i liknende kontekster har liknende betydning.
- Selve ideen er gammel (Firth, 1935; Wittgenstein, 1953; Harris, 1968).
- Hvorfor er dette nyttig?
- Å sammenligne **betydning** (vanskelig) reduseres til å sammenligne **kontekst** (enkelt)
 - ingen behov for annen forhåndskunnskap!
- Dagens regnekraft og enorme mengder digital tekst gjør at ideen nå kan omsettes i praksis i stor skala.
- Viktig del av grunnlaget for hvordan moderne språkmodeller fungerer.

- 1: Definer **vokabularet** – ordene vi ønsker å modellere.
- 2: Definer **kontekst** – f.eks. alle andre ord innenfor samme setning.
- 3: Opprett **trekkvektorene** – gitt et stort korpus, tell alle ord innenfor konteksten for alle forekomster av ord i vokabularet.
 - Eksempel:
 - La v representere ordet *buss*.
 - La trekktype nr. 3 telle hvor ofte ordet 'kjøre' forekommer i samme setning.
 - Da vil trekkverdien $v_3 = 7$ indikere at 'kjøre' er observert 7 ganger sammen med *buss*.
- 4: Vi kan måle **semantisk likhet** som **geometrisk nærhet**.



- De **nærmeste naboene** for et gitt ord i rommet vil typisk være semantisk relaterte.
- Semantisk likhet
 - liknende kontekster
 - geometrisk nærhet



- Vektorrom kan også representeres i form av en tabell eller en **matrise**.
- For n ord og m trekk vil vi få en $n \times m$ matrise.
- **Radene** representer ordene vi ønsker å modellere.
- **Kolonnene** angir verdiene for hvert trekk.

	aardvark	...	computer	data	result	pie	sugar
cherry	0	...	2	8	9	442	25
strawberry	0	...	0	0	1	60	19
digital	0	...	1670	1683	85	5	4
information	0	...	3325	3982	378	5	13

	aardvark	...	computer	data	result	pie	sugar
cherry	0	...	2	8	9	442	25
strawberry	0	...	0	0	1	60	19
digital	0	...	1670	1683	85	5	4
information	0	...	3325	3982	378	5	13



- I eksemplet over definerte vi 'kontekst' som alle ord i samme setning.
- Slike trekk kalles ofte *bag-of-words* (BoW) – 'ordsekker' – fordi vi ignorerer rekkefølge og struktur.
- Kan også defineres på andre måter, f.eks. kontekstvindu på ± 2 ord, e.l.
- Ordene som utgjør vokabularet og trekkene kan være de samme ($|V| \times |V|$ matrise), men ikke nødvendigvis.

rose er en rose er en rose er en rose (Gertrude Stein, 1913)

- Hvor mange ord er det?



rose er en rose er en rose er en rose (Gertrude Stein, 1913)

- Hvor mange ord er det?
- 3 **typer** og 10 **forekomster** (tokens).
- Ordtypene utgjør trekkene, ordforekomstene utgjør trekkverdiene.



Vi må først dele teksten opp i ord-liknende enheter!

Tokenisering

Vi må først dele teksten opp i ord-liknende enheter !

- **Tokenisering**: Splitter opp teksten til setninger og ord eller enda mindre enheter.
- Ulike grader av **normalisering**:
 - Hvordan håndtere store/små bokstaver, tall, tegnsetting, ...?
- **Stoppliste**: filtrerer ut høyfrekvente 'stoppord' som bidrar lite semantisk.
 - Typisk fra lukkede ordklasser, f.eks. funksjonsord som *av*, *det*, *et*, *sånn*, *å*, osv.
 - Tanken er at kun *innholdsord* gir relevant kontekst.
- I tillegg settes ofte en **frekvensgrense** for hvor ofte et ord må forekomme før det inkluderes som et trekk (f.eks $f \geq 10$).

- Forekomsten av ord i store tekstsamlinger (korpora) følger noen mønstre.
- Noen få ord dominerer.
- Funksjonsord (og, i, det, som, osv.) utgjør f.eks. en veldig stor andel.
- **Lang hale**: de fleste ordtypene forekommer sjelden.
- Typisk vil halvparten av ordene forekomme kun én gang.
- Lingvisten George Kingsley **Zipf** formaliserte denne empiriske regelmessigheten i 1935.






Image credits: @Vsauce: <https://www.youtube.com/watch?v=fCn8zs9120E>

- Om ord rangeres etter frekvens,
- så er frekvensen omtrent omvendt proporsjonal med rangeringen;
- ordet på plass r forekommer ca $1/r$ så ofte som det mest vanlige ordet:
- Det vanligste ordet forekommer ca. $2\times$ så ofte som det nest-mest vanlige; $3\times$ så ofte som det tredje; osv.
- En liknende zipfiansk distribusjon kan sees for mange andre typer data.




- **Høydimensjonale**: $d = |V| = \text{tusenvís}$
- **Sparse**: sparsomt med ikke-null verdier (dvs. de fleste elementene er null – hvorfor?)
- **Diskret**: hvert trekk representerer et gitt symbol eller ord




Representasjoner av 'kake'



Vektor



Embedding





Sammenslåing av ords betydninger

- En enkelt vektor for hvert ord
- Problem for flertydige ord

Sammenslåing av ords betydninger

- En enkelt vektor for hvert ord
- Problem for flertydige ord

Bias

- Menneskelig *bias* i treningsdataene vil gjenspeiles i ordvektorene
- F.eks. assosiasjoner mellom kjønn og stereotypiske yrker.

Sammenslåing av ords betydninger

- En enkelt vektor for hvert ord
- Problem for flertydige ord


Bias

- Menneskelig *bias* i treningsdataene vil gjenspeiles i ordvektorene
- F.eks. assosiasjoner mellom kjønn og stereotypiske yrker.

Antonymer


- Betydninger som er **motsetninger**
- *lang/kort, rask/treg, mørk/lys, opp/ned, stige/falle, varm/kald, inn/ut*
- Vanskelig å distribusjonelt skille fra synonymmer

- Ordvektorer lar oss representere og modellere semantisk **ordlikhet**.
- Hva med **setningslikhet** eller **dokumentlikhet**?



- Informasjonsgjenfinning
- Vi ønsker å kunne kvantifisere hvor **like** ulike **dokumenter** er.
- Eller hvor **relevante** ulike dokumenter er for en gitt **søkestreng**.
- 'Dokumentene' kan også være annen type tekst, som **setninger**.
- En enkel og utbredt tilnærming:
- Trekkene som representerer en tekst =
- **frekvenstillinger** av alle ordene som forekommer i teksten.
- Såkalte **bag-of-words** (BoW)-trekk: 'ordsekker'.
- Hver **ordtype** tilsvarer et **trekk** (en dimensjon); antall forekomster er verdien.

I love this movie! It's sweet, but with satirical humor. The dialogue is great and the adventure scenes are fun... It manages to be whimsical and romantic while laughing at the conventions of the fairy tale genre. I would recommend it to just about anyone. I've seen it several times, and I'm always happy to see it again whenever I have a friend who hasn't seen it yet!




adventure	1
and	3
fairy	1
genre	1
great	1
have	1
humor	1
I	5
it	6
satirical	1
seen	2
sweet	1
the	4
times	1
to	3
whimsical	1
would	1
yet	1
...	...

	battle	good	fool	wit
As You Like It	1	114	36	20
Twelfth Night	0	80	58	15
Julius Caesar	7	62	1	2
Henry V	13	89	4	3

- For en samling med N dokumenter og et vokabular V , så vil en BoW-representasjon gi en $N \times |V|$ matrise.
- **Kolonnene** representerer ord i vokabularet (mulige trekk)
- **Radene** representerer dokumentenes trekkvektorer
- Vi antar at dokumenter som deler mange av de samme ordene også deler mye av sitt semantiske innhold.

	battle	good	fool	wit
As You Like It	1	114	36	20
Twelfth Night	0	80	58	15
Julius Caesar	7	62	1	2
Henry V	13	89	4	3




	battle	good	fool	wit
As You Like It	1	114	36	20
Twelfth Night	0	80	58	15
Julius Caesar	7	62	1	2
Henry V	13	89	4	3

- Merk: Kunne også byttet om på rader og kolonner (jf. J&M)!

	battle	good	fool	wit
As You Like It	1	114	36	20
Twelfth Night	0	80	58	15
Julius Caesar	7	62	1	2
Henry V	13	89	4	3


- Merk: Kunne også byttet om på rader og kolonner (jf. J&M)!
- Merk 2: vi kan også se på **kolonnene** som vektorer som representerer **ord**!
- Ord som forekommer i mange av de samme dokumentene vil ofte være semantisk relaterte.
- Da er vi tilbake til den **distribusjonelle hypotesen**,
- men med en veldig grov definisjon av kontekst / trekk.

- Sentral oppgave i informasjonsgjenfinning (IR / *information retrieval*):
- Identifiser **relevante dokumenter** for en gitt **søkestreng** (*query*).
- Kan tenke på søkestrengen som et kort dokument og representere den som en vektor.
- Ranger dokumentene basert på avstanden mellom dokumentvektorene og søkevektoren.
- **Nærmeste naboene** = mest relevante.



- Rå frekvenstellinger er ikke alltid beste indikator på relevans.
- Bruker derfor gjerne en **vektingsfunksjon** på frekvensene.
- Mest brukt er **TF-IDF**: Term Frequency–Inverse Document Frequency
- Basert på et mål introdusert av Karen Sparck Jones i 1972

I love this movie! It's sweet, but with satirical humor. The dialogue is great and the adventure scenes are fun... It manages to be whimsical and romantic while laughing at the conventions of the fairy tale genre. I would recommend it to just about anyone. I've seen it several times, and I'm always happy to see it again whenever I have a friend who hasn't seen it yet!



adventure	1
and	3
fairy	1
genre	1
great	1
have	1
humor	1
I	5
it	6
satirical	1
seen	2
sweet	1
the	4
times	1
to	3
whimsical	1
would	1
yet	1
...	...



- **Termfrekvensen** $tf(t_i, d_j)$ angir antall ganger termen t_i forekommer i dokumentet d_j .

- **Termfrekvensen** $tf(t_i, d_j)$ angir antall ganger termen t_i forekommer i dokumentet d_j .
- **Dokumentfrekvensen** $df(t_i)$ angir det totale antallet dokumenter i samlingen som termen forekommer i.

- **Termfrekvensen** $tf(t_i, d_j)$ angir antall ganger termen t_i forekommer i dokumentet d_j .
- **Dokumentfrekvensen** $df(t_i)$ angir det totale antallet dokumenter i samlingen som termen forekommer i.
- **Invers dokumentfrekvens** er definert som $idf(t_i) = \log \left(\frac{N}{df(t_i)} \right)$, der N er det totale antall dokumenter i samlingen.

- **Termfrekvensen** $tf(t_i, d_j)$ angir antall ganger termen t_i forekommer i dokumentet d_j .
- **Dokumentfrekvensen** $df(t_i)$ angir det totale antallet dokumenter i samlingen som termen forekommer i.
- **Invers dokumentfrekvens** er definert som $idf(t_i) = \log \left(\frac{N}{df(t_i)} \right)$, der N er det totale antall dokumenter i samlingen.
- **Vekten** for en term t_i i dokument d_j beregnes da som: $tf-idf(t_i, d_j) = tf(t_i, d_j) \times idf(t_i)$
- En høy $tf-idf$ oppnås hvis en term har en *høy* frekvens i det gitte *dokumentet* og en *lav* frekvens i *dokumentsamlingen* totalt sett.
- Vektene vil dermed typisk filtrere ut de vanligste ordene.

- **Termfrekvensen** $tf(t_i, d_j)$ angir antall ganger termen t_i forekommer i dokumentet d_j .
- **Dokumentfrekvensen** $df(t_i)$ angir det totale antallet dokumenter i samlingen som termen forekommer i.
- **Invers dokumentfrekvens** er definert som $idf(t_i) = \log \left(\frac{N}{df(t_i)} \right)$, der N er det totale antall dokumenter i samlingen.
- **Vekten** for en term t_i i dokument d_j beregnes da som: $tf-idf(t_i, d_j) = tf(t_i, d_j) \times idf(t_i)$
- En høy tf-idf oppnås hvis en term har en *høy* frekvens i det gitte *dokumentet* og en *lav* frekvens i *dokumentsamlingen* totalt sett.
- Vektene vil dermed typisk filtrere ut de vanligste ordene.
- Varianten i J&M bruker såkalt 'sublineær tf-skalerting' der tf erstattes med $1 + \log(tf)$.
- Det finnes mange **varianter** (jf. BM25), men dere trenger ikke kunne disse.

- Tema for første obligatoriske innlevering:
- Lage ordvektorer for å måle semantisk likhet.
- BoW-trekk på setningsnivå.
- **Gruppearbeid** oppmuntres
- `https://www.uio.no/studier/emner/matnat/ifi/IN1160/v26/obliger.html`
- Delta på gruppene (lab + seminar)!

- Mer om vektorrommodeller
- Dokumentklassifikasjon med KNN og Rocchio
- Tema for innlevering 1b
- Les:
- Manning, Raghavan & Schütze: fra kapittel 14 ('Vector space classification'), les frem til (men ikke med) 14.3.1
- Shah: les om kNN-klassifikasjon i seksjon 5.1 og 5.2
- Jurafsky & Martin: seksjon 4.9 ('Evaluation: Precision, Recall, F-measure') og 4.10 ('Test sets and Cross-validation')