

UNIVERSITETET I OSLO

Beslutningstrær,
Ensemble-metoder og
Tilfeldige Skoger


Kai Olav Ellefsen
*Gruppe for Robotikk og Intelligente
Systemer (ROBIN)*

IN1160 – Introduksjon til
maskinlæring (Vår 2026)




Bonus-Pensum

- Hadde opprinnelig tenkt å bruke denne, som *var* gratis tilgjengelig på O'Reilly
 - Kapittel 6: «Decision Trees»
 - Kapittel 7: «Ensemble Learning and Random Forests»
- UiO har avsluttet abonnementet med O'Reilly, derfor er disse kapitlene «bonus»-pensum



Pensum

- Shah kap 5.3 (minus 5.3.3) og 5.4
- Og **disse slides'ene**
- Shah har forholdsvis lite om beslutningstrær og ensembler, så slidesene går en del mer i detalj enn boka





Del 1: Beslutningstrær

Engelsk: «Decision Trees»



Hvorfor beslutningstrær?

- En fundamental ML-algoritme, som er **lett å forstå** og det som læres er **lett å tolke!**
- Kan gjøre **både regresjon og klassifikasjon**
- Beslutningstrær er byggesteiner i **Tilfeldige Skoger**, som er **blant de kraftigste** maskinlæringsalgoritmene vi har
 - **Særlig gode om vi har tabell-baserte data**, der ulike kolonner kan ha veldig ulike verdi-intervaller

Hvor mange av dere har sett trær før (som datastruktur)?

Trær som datastruktur

- En samling av **noder** og **kanter**
- **Hierarkisk:** Hver node har kun 1 «forelder»
- **Uten løkker:** Ingen piler som går «bakover»
- Mappene på datamaskinen deres er organisert som et tre
- Likner litt på et tre med grener og stamme fra naturen, bare at vi tegner det **opp-ned**.




Kilde: Wikipedia

Er et nevralt nettverk et tre?

Er et nevralt nettverk et tre?


- Nei, for nettverket har ikke en hierarkisk struktur – hver node kan ha mange «foreldre»



Hva er et beslutningstre?

- En serie med **spørsmål vi kan spørre når vi skal predikere** verdien til et datapunkt
- Hver **node** i treet stiller et nytt spørsmål
- Hver **kant** representerer et **sva**r på spørsmålet
- Den øverste noden kalles **roten** i treet
- De **nederste nodene** gir oss den endelige **prediksjonen** – disse kalles **løvnoder**


Survival of passengers on the Titanic



Hvordan bygger vi dette?

- Vi lærer treet basert på data
- Eksempel: Mange passasjerer fra Titanic med gitte **trekk**, og **info om klassifisering** (overlevelse)
- Ved hvert steg i byggingen prøver vi å finne **det trekket som best lar oss skille de ulike klassene** (den beste «splitten»)


Survival of passengers on the Titanic



Eksempel

- Kjønn viste seg å være **det som skiller mest** på overlevelse – vi **splitter på det først**.
 - Er man kvinne, overlevde man sannsynligvis (73% sikkert)
- Blant mennene skiller alder mest. Vi splitter på det trekket
 - Kun 17% av menn over 9.5 år overlevde
- **Vi fortsetter å splitte til vi når et stopp-kriterium**

Survival of passengers on the Titanic



Kodeeksempel: Trene opp beslutningstre med scikit-learn

- jupyterhub



Iris Versicolor





Iris Setosa




Iris Virginica

Det ferdige treet




Hva har treet lært?

- Value-feltene indikerer andelen instanser fra [setosa, versicolor, virginica]
- **Hvordan kan vi formulere hva treet har lært?**



Hva har treet lært?

- Value-feltene indikerer andelen instanser fra [setosa, versicolor, virginica]
- **Hvordan kan vi formulere hva treet har lært?**
 - Har vi liten lengde på bladet, er det en setosa.
 - Har vi stor lengde, har vi:
 - Liten bredde: versicolor
 - Stor bredde: virginica




Å bruke treet til å predikere

- Vi finner en blomst
- Måler kronbladene
 - Lengde: 3cm
 - Bredde: 1cm
- **Hvilken blomst er dette?**




Å bruke treet til å predikere

- Vi finner en blomst
- Måler kronbladene
 - Lengde 3cm
 - Bredde 1cm
- **Hvilken blomst er dette?**




Å bruke treet til å predikere

- Vi finner en blomst
- Måler kronbladene
 - Lengde 3cm
 - Bredde 1cm
- **Hvilken blomst er dette?**




Treet vårt sa «versicolor»

- Hvor sikre kan vi være på dette?




Treet vårt sa «versicolor»

- Hvor sikre kan vi være på dette?
 - **91% (49 av 54)** sikre hvis blomsten er blant **treningsdataene**
 - Hvis den er ny (ikke sett under trening): Vanskeligere å si. Vi har ikke **så langt brukt noe test/valideringssett**



Noen fordeler med beslutningstrær


- Veldig lett å tolke hva de har lært (**KI-forklarbarhet**)
- **Krever ikke preprosessering** av data – vi bruker bare tallene direkte



Jupyter

- <https://jupyterhub.uio.no/>
- **Bruke Treet til å Predikere**

Beslutningsgrensene treet har lært




Forklarbarhet/tolkbarhet

- Det er enkelt å tolke hva beslutningstreet har lært. Slike metoder kaller vi ofte «**hvit boks**» **metoder** – vi kan **kikke inn i dem** og forstå hva som skjer
- Mange mer avanserte metoder er vanskeligere å forklare/tolke. De kalles «**sort boks**» **metoder**
- Et eksempel er nevrale nettverk. Det er ofte vanskelig å finne ut hvorfor de tar valgene de gjør
- Feltet **forklarbar KI** (eXplainable Artificial Intelligence – XAI) utvikler teknikker for å gjøre modeller/algoritmer mer forklarbare

Hvordan finne den riktige «splitten»?


- Det finnes mange metoder for dette, hovedpoenget er å **lete etter den splitten som gir de «reneste»/sikreste deltrærne (sub-trees)** – altså at de har **mest mulig har overvekt av en enkelt klasse**.
- Standard-metoden i scikit-learn heter **Gini-urenhet**
- Målet **entropi** brukes i Shah, det sier noe om **hvor mye mer informasjon** vi får av hver splitt.

Survival of passengers on the Titanic




Entropi i binær klassifisering

- Datapunktene våre tilhører klasse 0 eller 1
- **X-aksen: Hvor stor andel** av datapunktene i en node tilhører klasse 1?
- **Y-aksen: Nodens entropi.**
- Mer usikkerhet $\rightarrow$ Høyere entropi
- Vi **ønsker den splitten som gir lavest entropi i hver node**– skiller de 2 ulike klassene best mulig




Entropi – eksempel 1

- Tenk dere at alle mennene på Titanic Døde og alle kvinnene overlevde.
 - Sannsynlighet for overlevelse for menn ($\Pr(X=1)$) = 0.
 - Sannsynlighet for overlevelse for kvinner ($\Pr(X=1)$) = 1.
- **Entropi 0** – to helt rene noder, lav entropi, lav usikkerhet.
Godt trekk å splitte på




Entropi – eksempel 2

- Tenk dere at halvparten av alle menn døde og halvparten av alle kvinner døde.
 - Sannsynlighet for overlevelse for menn ($\Pr(X=1)$) = 0.5
 - Sannsynlighet for overlevelse for kvinner ($\Pr(X=1)$) = 0.5
- **Entropi 1** – to helt urene noder, høy entropi, høy usikkerhet.
Dårlig trekk å splitte på



Treningsalgoritme (CART: Classification and Regression Tree)

- Hvordan bygge treet i praksis?
Finnes *flere ulike algoritmer* for dette. Mange er **grådige**.
- Fellestrekk: Ved hvert splitt, prøv å finn *trekket* (feature) k , og *terskelverdien* t_k som hjelper oss best å skille de ulike klassene
- Fortsett:
 - Til man kun har rene noder eller
 - Til treet når en maks-dybde eller
 - Til man når andre stoppkriterier



Overtilpasning til treningsdata


- Beslutningstrær *gjør få antakelser* om dataene. Dette gir dem stor frihet til å **modellere dataene nøyaktig**
- Det gjør også at de ***overtilpasser seg treningsdataene*** hvis vi ikke passer godt på
- Vi bruker ***regularisering*** for å *begrense treets frihet* under trening, og dermed redusere overtilpasning
- **Hva kan vi regularisere? Hvordan begrenser vi friheten til et beslutningstre?**

Regularisering – mye kan begrenses


- Maksimal dybde
- Maksimalt antall trekk som vurderes i hver splitt
- Maksimalt antall løvnoder
- Minimum antall datapunkter en node må ha for å kunne splittes
- Minimum antall datapunkter en løvnoder må ha for å opprettes
- Når vi **øker minimumsverdier** eller **senker maksimumsverdier** **begrenser vi friheten til å overtilpasse**

Eksempel


- Regularisering gjennom hyperparametere
- Jobber på et datasett som lett kan overtilpasses
- **Hvordan ser en overtilpasset løsning ut her?**
- **Hvordan ser en god løsning ut?**



Jupyter Notebook – Regularisering




Beslutningstrær kan også brukes til regresjon





Begrensninger ved beslutningstrær (1)

- Sensitivitet for rotering av datapunktene i treningssettet
- Alle splitter sammenlikner om et enkelt trekk er over eller under en gitt verdi. Det gir helt vannrette eller loddrette splitter.



Begrensninger ved beslutningstrær (2)

- Stor **varians**: Små endringer i hyperparametere gir store utslag
- Kan til og med få **store forskjeller med samme hyperparametere** pga. tilfeldigheter i algoritmen når den velger trekk å splitte på
- En vei mot **mindre varians**: **Ensembler** av trær (tilfeldige skoger)



A photograph of a dense forest with tall, thin trees. Sunlight is filtering through the canopy, creating a dappled light effect on the forest floor. The text is overlaid on the center of the image.

Del 2: Ensemble-metoder og Tilfældige Skoger

Engelsk: Random forests


Hvorfor ensemble

- Hvis vi har N «ganske gode» modeller, kan de kombinert bli enda bedre
- For eksempel, **trene N ulike beslutningstrær** på ulike deler av dataen vår. Endelig svar lager vi ved å ha en avstemming blant dem
 - Dette kalles en **tilfeldig skog** (random forest)
- Ensemble-metoder er ofte blant de aller beste i praksis, og vinner ofte konkurranser i maskinlæring når **dataene er tabell-baserte** (altså **hvert datapunkt representert som en mengde med trekk**)

Hvorfor ensemble


- Motivert av «wisdom of crowds»: Om mange ikke-eksperter går sammen om å gi et svar, er ofte gjennomsnitts-svaret deres veldig bra.
 - <https://www.youtube.com/watch?v=35xkhCaG1wA>
- <https://www.mentimeter.com/app/presentation/aly14d5qyh3exzji7mmcin465hag9f/edit?question=honr7t52pyxy>

Avstemningsklassifikator (Voting Classifier)



Hard Avstemmingsklassifikator (Hard Voting Classifier)

- Bruk den vanligste klassifikasjonen som ensembles svar
- **Ensemblet fungerer ofte mye bedre enn de individuelle modellene** – selv når modellene er «*svake lærere*» (weak learners)
- Svake lærere: Modeller som har lært å **bare så vidt være bedre enn tilfeldig** gjetting




Analogi for ensemble av svake lærere

- Tenk deg at du har en mynt med «bias»: Den blir kron 51% av gangene, mynt 49%.
- Kaster vi 10 ganger er det lite sannsynlig at vi oppdager biasen
- Kaster vi 1000 er det mer sannsynlig
- Kaster vi 10.000 ganger er det nesten helt sikkert




Simulerte myntkast - data

Etter 1000 kast er det 75% sikkert at vi har over halvparten kron.




Ensemble av svake lærere

- Anta **hver klassifikator bare gjetter riktig svar 51% av gangene** (binær klassifisering)
- Men vi har 1000 slike binære klassifikatorer
- Da kan vi få **opp til 75% korrekt svar!**
- Men: Det krever en **viktig antakelse** om de ulike modellene – **hvilken?**



Uavhengighet


- For å få mest ut av ensemblet bør enkeltmodellene **være så uavhengige som mulig**
- Gjør de **samme typen feil**, mister vi effekten av at de kan kompensere for hverandres unøyaktigheter
- **Hvordan kan vi gjøre modellene uavhengige/ulike?**



Ensemble av svake lærere - uavhengighet

Vi kan gjøre dem uavhengige ved å:

- Trene på ulike deler av datasettet
- Bruke ulike typer algoritmer



Demo

- Vi bruker scikit-learn's VotingClassifier.
- Den tar inn modellene vi vil ha i ensemblet, og trener ensemblet for oss.

```
voting_clf = VotingClassifier(  
    estimators=[  
        ('lr', LogisticRegression(random_state=42)),  
        ('rf', RandomForestClassifier(random_state=42)),  
        ('svc', SVC(random_state=42))  
    ]  
)  
voting_clf.fit(X_train, y_train)
```


Myk avstemming (soft voting)

- Hvis alle klassifikatorene kan estimere sannsynligheter for de ulike klassene, kan vi **bruke disse sannsynlighetene i ensemblet**. Dette kan gi større nøyaktighet.
- For eksempel, tenk dere disse sannsynlighetsverdiene fra 3 klassifikatorer i binær klassifisering
- Majoritetsstemmen er Klasse A, men tar vi hensyn til sannsynlighetene kan klasse B se mer lovende ut.
- Soft voting Demo

	Klasse A	Klasse B
Klassifikator 1	51%	49%
Klassifikator 2	1%	99%
Klassifikator 3	51%	49%

Generalisering

- Hvert enkelt **beslutningstre** er ofte **overtilpasset** til dataene
- Men **ensemblet** samlet lærer noe **mer generelt**. Det har gjerne mye **mindre varians**



Tilfeldige skoger (Random forests)

- En Tilfeldig skog er et **ensemble av beslutningstrær**, med spesielle triks for å gjøre de **ulike trærne uavhengige**
- Scikit-learn:

```
from sklearn.ensemble import RandomForestClassifier

rnd_clf = RandomForestClassifier(n_estimators=500, max_leaf_nodes=16,
                                n_jobs=-1, random_state=42)

rnd_clf.fit(X_train, y_train)

y_pred_rf = rnd_clf.predict(X_test)
```






Tilfeldige skoger - uavhengigheter

- Tilfeldige Skoger passer ekstra på at de ulike trærne blir uavhengige.
- **Hvordan gjør vi de ulike beslutningstrærne uavhengige/ulike?**

Tilfeldige skoger - uavhengigheter


- Tilfeldige Skoger passer ekstra på at de ulike trærne blir uavhengige.
- **Hvordan gjør vi de ulike beslutningstrærne uavhengige/ulike?**
 - **Tilfeldige datapunkter til hvert tre**
 - Tilfeldige trekk: Istedenfor å velge blant alle trekk **når vi skal gjøre en splitt, velg blant en tilfeldig delmengde av trekkene**
 - Standard i scikit-learn: Vi har $\sqrt{n}$ trekk å velge blant for hver splitt, gitt at vi har n trekk totalt

	Independent variables		
	A	B	C
Training instances	A_1	B_1	C_1
	A_2	B_2	C_2
	A_3	B_3	C_3
	A_4	B_4	C_4




Figur: Shah

Beslutningstre vs tilfældig skog



Decision Tree



Random Forest

Oppsummering

- **Beslutningstrær** er **enkle** og har fordelen at de er svært **tolkbare** – vi kan se hva de har lært
- Men de har **stor grad av varians**, påvirkes mye av små tilfeldigheter
- **Ensemble-metoder** lar oss bruke **samlinger av svake lærere** til å lage gode prediksjoner
- Hvis ensemble-medlemmene er **uavhengige** kan deres samlede avstemming være mye bedre enn enkeltmedlemmer
- Ensemble av beslutningstrær (**tilfeldige skoger**) er et kraftig verktøy, særlig om vi har data som kan representeres i en tabell