

UNIVERSITETET I OSLO

Filosofi og Fremtid

Erik Velldal og Kai Olav Ellefsen

IN1160 – Introduksjon til
maskinlæring (Vår 2026)



Del 2 – Veien videre for KI

1. Generell intelligens, intelligenseksplosjon og Superintelligens
2. Begrensninger ved nåværende KI-systemer
3. Forklarbarhet

Generell intelligens, intelligenseksplosjon og Superintelligens



Kunstig Generell Intelligens (KGI)

(eng: AGI – Artificial General Intelligence)

- KI-systemer har **tradisjonelt vært gode til én bestemt oppgave**, men hatt null kompetanse på alt annet – en «**Spesialisert Intelligens**»
 - For eksempel, vil en KI-algoritme for å spille sjakk typisk ikke kunne mestre andre spill, og i hvert fall ikke kunne løse differensiallikninger
- **Menneskelig intelligens er mer generell** – vi kan gjøre mange ulike oppgaver som krever ulik type intelligens
- **Mange store KI-firmaer har som mål å utvikle KGI** – deriblant OpenAI, Google DeepMind og Meta.

Har kraftige språkmodeller generell
intelligens?

KGI – Hvor står vi?

- De kraftige språkmodellene fra de siste årene har tatt oss **nærmere en generell intelligens – de kan «litt om alt»**: Spille sjakk, løse likninger, forklare hvordan man lager kaffe, etc.
- Men de har veldig **ujevn kvalitet**: På noen områder er de veldig intelligente, på andre overraskende dumme (mer om dette senere)
- Dette fenomenet kalles av og til «**taggete intelligens**» ([Jagged Intelligence](#))



Superintelligens


- Et KI-system som er **mer intelligent enn menneskelige genier på omtrent alle områder**
- Noen forskere tror vi **kort tid etter vi har utviklet KGI kan få superintelligens** – siden KI-systemene kan være med på å utvikle nye, bedre systemer, og så videre. En **intelligens-eksplasjon**




Superintelligens – Antakelser

1. Vi lager **litt og litt mer intelligente KI-systemer** hvert år (og vi treffer ikke en “vegg” i fremgangen)
2. Mennesker er **langt fra toppen** av intelligensskalaen
3. Intelligente KI-agenter kan **akselerere fremdriften**

Intelligens



Intelligens





“Humans, limited by slow biological evolution, couldn’t compete and would be superseded by A.I.”



AI is our “biggest existential threat”



I am in the camp that is concerned about super intelligence.



Yoshua Bengio har fått det som sees på som nobelprisen for informatikk. Her åpner han forskningssenteret TRUST ved UiO. Foto: Christoffer Hals

Under åpningen av det nye KI-senteret TRUST kom stjerneforsker Yoshua Bengio med en tydelig advarsel

Den teknologiske utviklingen innen KI går så raskt at vi risikerer å skape systemer som mennesker ikke lenger har kontroll over.

Markets →

DOW	46,208.47	1.38% ▲
S&P 500	6,581.00	1.15% ▲
NASDAQ	21,046.76	1.38% ▲

Fear & Greed Index →



Latest Market News →

A deal with Iran wouldn't lower your gas prices


After losing in court, the Pentagon moves to

Trump's ICE airport idea came after a radio h

BUSINESS > TECH • 4 MIN READ

The 'godfather of AI' reveals the only way humanity can survive superintelligent AI

UPDATED AUG 14, 2025 ▾

By  Matt Egan

AI expert: 'We'll be toast' without changes in AI technology



Air Canada passenger on 'harrowing moment' plane collided with...



Will the Supreme Court limit mail-in balloting ahead of midterms?


• • • • •




Las Vegas — Geoffrey Hinton, known as the “godfather of AI,” fears the technology he helped build could wipe out humanity — and “tech bros” are

Hvorfor kan en ekstremt intelligent maskin være farlig?


- Hvis maskinen har **mål som ikke er samstemt** med våre (eng: misaligned)
- Og den er **ekstremt intelligent/mektig**
- Så kan det bli **vanskelig for oss å hindre den i å oppnå disse målene**
- Kan en løsning være å bare kode inn målene veldig eksplisitt?





Problem:
Belønningsmanipulering
(eng: Reward Tampering)

Bilde fra DeepMind:
<https://medium.com/@deepmindsafetyresearch/designing-agent-incentives-to-avoid-reward-tampering-4380c1bb6cd>




Mange forskere mener at bekymringen for superintelligens er overdrevet

Melanie Mitchell



Yann LeCun



Andrew Ng



Hva er argumentene mot å bekymre seg for
superintelligens?

Hva er argumentene mot å bekymre seg for superintelligens?

1. Nåværende KI-systemer er **så langt unna superintelligens**, at det er lite konstruktivt å bekymre seg for dette
2. Vi har **utfordringer som haster mer** – medias fokus på superintelligens gjør at vi mister oppmerksomheten på mer akutte temaer (mer om disse neste uke)
3. Det forskes faktisk ganske mye på hvordan vi **bedre forstår og kontrollerer** KI-algoritmer

Worrying about
AI evil superintelligence today
is like worrying about
***overpopulation on
the planet Mars.***

***We haven't even
landed on
the planet yet!***



Begrensninger ved dagens KI- systemer



Kilde: Microsoft Copilot



Make an image of a robot pouring coffee into a full mug so that it spills over, and there is coffee all over the table

Bing bildeskaper | 1024 x 1024 jpg | Opprettet nå

Opprett på nytt

Del

Lagre

Last ned

Tilbakemelding

Bruk som bakgrunn

Taggete intelligens

- På noen områder er fortsatt menneskehjernen mye bedre enn KI-systemer
- Dette er litt paradoksalt, siden kraftige KI-systemer løser mange oppgaver bedre enn oss
- Dette er den «**taggete intelligensen**» vi var inne på tidligere – vi skal nå se litt på ting KI-modeller ikke får til



1) Robusthet

- Dyp forsterkende læring: Dype nevrale nettverk kan lære seg å mestre mange spill/utfordringer via prøving og feiling, ved å styre en agent, og få belønning/ straff
- Slike agenter kan fort bli mye bedre enn mennesker i et gitt spill (som “breakout”, til høyre)



The image features the BBC News logo in the bottom-left corner. The logo consists of the letters 'BBC' in white, each inside a small square, followed by the word 'NEWS' in a larger, white, sans-serif font. This is set against a solid red rectangular background. The entire image is heavily corrupted with digital artifacts. Two prominent vertical blue lines run from the top to the bottom of the frame. At the top, there are several horizontal bars of color: a thick red one, a thinner orange one, and a green one with a jagged, pixelated edge. The rest of the image is a dark, noisy black with scattered small, bright pixels and a few small horizontal streaks of color at the bottom.

BBC
NEWS

Robusthet

- Selv om agenten spiller spillet perfekt, har den ikke skjønnet “reglene” i spillet. Den skjønner ikke hva ballen og klossene representerer
- Dermed lærer den en “snarvei” til å få mange poeng, heller enn en generell spillforståelse
- Slike snarveier er sårbare – agenten kan lett lures

Minimalistic Attacks: How Little it Takes to Fool Deep Reinforcement Learning Policies

Xinghua Qu, *Student Member, IEEE*, Zhu Sun, Yew Soon Ong, *Fellow, IEEE*, Pengfei Wei, Abhishek Gupta

Abstract—Recent studies have revealed that neural network based policies can be easily fooled by adversarial examples. However, while most prior works analyze the effects of perturbing every pixel of every frame assuming white-box policy access, in this paper we take a more restrictive view towards adversary generation - with the goal of unveiling the limits of a model’s vulnerability. In particular, we explore minimalistic attacks by defining three key settings: (1) *black-box policy access*: where the attacker only has access to the input (state) and output (action probability) of an RL policy; (2) *fractional-state adversary*: where only several pixels are perturbed, with the extreme case being a single-pixel adversary; and (3) *tactically-chanced attack*: where only significant frames are tactically chosen to be attacked. We formulate the adversarial attack by accommodating the three key settings, and explore their potency on six Atari games by examining four fully trained state-of-the-art policies. In Breakout, for example, we surprisingly find that: (i) all policies showcase significant performance degradation by merely modifying 0.01% of the input state, and (ii) the policy trained by DQN is totally deceived by perturbation to only 1% frames.

Index Terms—Reinforcement Learning, Adversarial Attack.

I. INTRODUCTION

Deep learning [1] has been widely regarded as a promising technique in reinforcement learning (RL), where the goal of an RL agent is to maximize its expected accumulated reward by interacting with a given environment. Although deep neural network (DNN) policies have achieved super human performance on various challenging tasks (e.g., video games, robotics and classical control [2]), recent studies have shown that these policies are easily deceived under adversarial attacks [3]–[5]. These works are however found to make some common assumptions, viz., (1) *white-box policy access*: where the adversarial examples are analytically computed by back-propagating through known neural network weights, (2) *full-state adversary*: where the adversary changes almost all pixels in the state, and (3) *fully-chanced attack*: where the attacker strikes the policy at every frame.

Given that most prior works analyze the effects of perturbing every pixel of every frame assuming white-box policy




Fig. 1: The single pixel attack on Atari Breakout.

access, we propose to take a more restricted view towards adversary generation - with the goal of exploring the limits of a DNN model’s vulnerability in RL. In this paper, we thus focus on minimalistic attacks by only considering adversarial examples that perturb limited number of pixels in selected frames, and under the restricted black-box policy access. In other words, we intend to unveil how little it really takes to successfully fool state-of-the-art RL policies. Our study is based on three restrictive settings, namely, *black-box policy access*, *fractional-state adversary*, and *tactically-chanced attack*. These concepts are detailed next.

Black-box Policy Access (BPA). Most previous studies focus on a white-box setting [5], that allows full access to a policy network for back-propagation. However, most systems do not release their internal configurations (i.e., network structure and weights), only allowing the model to be queried; this makes the white-box assumption too optimistic from an attacker’s perspective [6]. In contrast, we use a BPA setting, where the attacker only has access to the input and output of a policy.

Fractional-State Adversary (FSA). In the FSA setting, the adversary only perturbs a small fraction of the input state. This, in the extreme situation, corresponds to the single-pixel attack shown in Fig. 1, where perturbing a single pixel of the input state is found to change the action prescription from ‘RIGHT’ to ‘LEFT’. In contrast, most previous efforts [5] are mainly based on a full-state adversary (i.e., the number of modified pixels is fairly large, usually spanning the entire frame).

Tactically-Chanced Attack (TCA). In previously studied RL adversarial attacks [3], [7], [8], the adversary strikes the policy on every frame of an episode; this is a setting termed as the fully-chanced attack. Contrarily, we investigate a relatively restrictive case where the attacker only strikes at a few selected frames - a setting we term as *tactically-chanced attack*, where

XH. Qu, is with the Computational Intelligence Lab, School of Computer Science and Engineering, Nanyang Technological University, Singapore, 639798 (email: xinghua001@e.ntu.edu.sg)

Z. Sun is with School of Electrical and Electronic Engineering, Nanyang Technological University, Singapore 639798 (email: sunzhuntu@gmail.com)

Y.-S. Ong is with the Data Science and Artificial Intelligence Research Centre, School of Computer Science and Engineering, Nanyang Technological University, Singapore 639798 (email: asysong@ntu.edu.sg)

P. Wei is with Department of Computer Science, National University of Singapore, Singapore 119077 (email: weipf@comp.nus.edu.sg)

A. Gupta is with Singapore Institute of Manufacturing Technology (SIMTech), A*STAR, Singapore 138634 (email: abhishek_gupta@simtech.a-star.edu.sg)

Robusthet

- Noe liknende skjer også i andre former for læring
- **Veiledet læring plukker gjerne opp “snarveier” til klassifisering** heller enn å forstå dataene våre ordentlig
- Det gjør at også systemer basert på veiledet læring kan være overraskende lite robuste

Robust Physical-World Attacks on Deep Learning Visual Classification

Kevin Eykholt^{*1}, Ivan Evtimov^{*2}, Earlene Fernandes², Bo Li³,
Amir Rahmati⁴, Chaowei Xiao¹, Atul Prakash¹, Tadayoshi Kohno², and Dawn Song³

¹University of Michigan, Ann Arbor

²University of Washington

³University of California, Berkeley

⁴Samsung Research America and Stony Brook University



Figure 1:

The left image shows real graffiti on a stop sign, something that most humans would not think is suspicious. The right image shows our a physical perturbation applied to a stop sign. We design our perturbations to mimic graffiti, and thus “hide in the human psyche.”

Robusthet

- Noe liknende skjer også i andre former for læring
- **Veiledet læring plukker gjerne opp “snarveier” til klassifisering heller enn å forstå dataene våre ordentlig**
- Det gjør at også systemer basert på veiledet læring kan være overraskende lite robuste



Fig. 6. Author 3 predicted(90.2%) as famous Norwegian cross country skier Petter Northug.

Attacking state-of-the-art face recognition networks
with adversarial examples

Mats H. L. Tveter
University of Oslo
Institute of Informatics
Oslo, Norway
mhtvteter@ifi.uio.no

Wonho Lee
University of Oslo
Institute of Informatics
Oslo, Norway
wonhol@ifi.uio.no


Mathias K. Nilsen
University of Oslo
Institute of Informatics
Oslo, Norway
mathiani@ifi.uio.no

Bruno C. da Silva
Federal University of Rio Grande do Sul
Institute of Informatics
Porto Alegre, RS, Brazil
bsilva@inf.ufrgs.br

2) Hallusinering

- Generative KI-systemer er kjent for å ha en tendens til å «**hallusinere**»
- Med dette mener vi at de **finner på uriktig informasjon**, som de (ofte svært selvsikkert) presenterer som fakta
- Dette skyldes til dels måten de trenes opp på – der de under trening oppfordres til å gjette neste ut-data best mulig (og ikke til å stoppe opp og si «jeg vet ikke»).
- «Resonnerende» LLM'er, som iterativt forbedrer sine svar hallusinerer mindre – men problemet er fremdeles tilstede

Jeg må vaske bilen. Vaskehallen er bare 100 meter unna, bør jeg kjøre eller gå dit? Svar med maks 3 setninger




Copilot

Gå – 100 meter er så kort at det tar mindre tid å gå enn å starte bilen. Du sparer både drivstoff og unødvendig slitasje. Bonus: litt frisk luft!



Jeg må vaske bilen. Vaskehallen er bare 100 meter unna, bør jeg kjøre eller gå dit? Svar med maks 3 setninger



Copilot

Resonnering er fullført i 2 trinn >

Kjør bilen dit – du må ha bilen med inn i vaskehallen. Du kan eventuelt gå først for å sjekke kø eller betaling, men selve vasken krever kjøring. Ta en liten gåtur etterpå for å få noen ekstra steg.



Hallusinering

- Vi ser også en form for **hallusinering i andre modaliteter** enn tekst
- For eksempel finner bilde- og video-modeller gjerne på ting som ikke hører hjemme – eksempel:

<https://en.wikipedia.org/wiki/File:Photoreal-train.webm>

Begrensninger - oppsummert


- Den raske fremgangen i KI bidrar til å løse noen fundamentale begrensninger.
- Men KI-modeller forstår ikke verden som et menneske – så vi må forvente at de *feiler på overraskende måter*.

Forklarbarhet

- Vi har sett at **kraftige KI-systemer kan være farlige** hvis de har andre mål enn oss, og at **KI-systemer feiler på uforutsette måter**
- En «**løsning**» på begge disse problemene kan være å gjøre **KI-systemer mer forklarbare/ tolkbare**: Skjønner vi **hva som foregår på innsiden**, blir risikoen lavere, og feilene mer forståelige.


Forklarbar KI

(eng: Explainable AI – XAI)




Slides bygger på innhold laget av
Hans Moen, Aalborg Universitet

Ytelse VS Tolkbarehet




Ytelse VS Tolkbarhet



Ytelse VS Tolkbarhet

Forskning på forklarbar KI



Ytelse (og kompleksitet?)

- Transformers
- Rekurrente nevrale nettverk
- Konvolusjonsnettverk
- Beslutningstrær
- Lineær regresjon

Tolkbarhet

Motivasjon

- Høy klassifiseringsnøyaktighet er bra, men ofte trenger vi også å vite hvorfor modellen klassifiserer som den gjør
- Dette kan være nyttig for:
 - **Forståelse** – Hvorfor predikerer modellen dette?
 - **Tillit** – Kan vi stole på modellen?
 - **Debugging og videre utvikling** – Bruker modellene trekkene på måten vi forventet? Er det nye data vi kan samle som kan gjøre den bedre?



Pasienten føler seg ofte slapp

Pasienten

føler

seg

ofte

slapp

Maskinlæringsmodell

Diagnose-klassifikator


0.2 – Influenza

0.9 – Slapphet


0.1 – Forkjølelse

0.3 – Matallergi


Hvorfor valgte modellen **Slapphet**?



Kan vi få en forklaring? Hvordan?



Kan vi få en forklaring? Hvordan?



Forklarbarhet - Eksempler


Forklarbarhet for bilder



(a) Original Image



(b) Explaining *Electric guitar*



(c) Explaining *Acoustic guitar*



(d) Explaining *Labrador*

Figure 4: Explaining an image classification prediction made by Google's Inception neural network. The top 3 classes predicted are "Electric Guitar" ($p = 0.32$), "Acoustic guitar" ($p = 0.24$) and "Labrador" ($p = 0.21$)

Kilde: Ribeiro et al. (2016) "Why should I trust you?" Explaining the predictions of any classifier

Forklarbarhet for bilder

Only 1 mistake!




Predicted: **wolf**
True: **wolf**




Predicted: **husky**
True: **husky**



Predicted: **wolf**
True: **wolf**



Predicted: **wolf**
True: **husky**




Predicted: **husky**
True: **husky**




Predicted: **wolf**
True: **wolf**

Forklarbarhet for bilder




Forklarbarhet for bilder

Modellen lærte seg å detektere snø
istedenfor å gjenkjenne ulver




Kilde: https://youtu.be/EbpU4p_0hes?t=1972

Forklarbarhet for tekstklassifisering



Forklarbarhet for tekstklassifisering


- Vi kan se på hvor mye (og i hvilken retning) hvert ord påvirket klassifiseringen («word attribution»)



(Det ser ut som modellen bruker ordene fornuftig her!)

Sub-optimal klassifikator

Pasienten føler seg ofte slapp →




0.2 – Influenza

0.9 – Slapphet

0.1 – Forkjølelse

0.3 – Matallergi

Han føler seg energisk →



0.2 – Influenza

0.9 – Slapphet

0.1 – Forkjølelse


0.3 – Matallergi

Forklarbarhet i forsterkende læring

- Vi så tidligere at agenter som har lært seg å løse en oppgave svært godt kan ha overraskende lite robusthet
- Forklarbarhetsteknikker kan hjelpe oss å finne ut hvorfor


Minimalistic Attacks: How Little Takes to Fool Deep Reinforcement Learning Policies

Xinghua Qu, *Student Member, IEEE*, Zhu Sun, Yew Soon Ong, *Fellow, IEEE*, Pengfei Wei, Abhishek Gupta




Visualizing and Understanding Atari Agents

Sam Greydanus¹ Anurag Koul¹ Jonathan Dodge¹ Alan Fern¹



Eksempel



(a) Pong: kill shot I



(b) Pong: kill shot II

Forklarbarhet - Oppsummering

- **Mer komplekse** ML-modeller er vanskeligere å forstå og **mindre forklarbare**
- Forskning på **forklarbarhet** kan hjelpe oss, ofte ved å analysere **hvordan inndata og utdata henger sammen**
- Dette kan hjelpe oss å **oppdage problemer vi ikke ville sett** ved å bare fokusere på **ytelsen** til modellen

