

Det matematisk-naturvitenskapelige fakultet
Institutt for informatikk (IFI)

Etikk og samfunnskonsekvenser

Lilja Øvrelid
Språkteknologigruppen (LTG)

IN1160 - Introduksjon til
maskinlæring (Vår 2026)



UNIVERSITETET
I OSLO



The Battle Over Books3 Could Change AI Forever

Copyright activists are on a mission to wipe a popular generative AI training set from the internet. Success could alter the industry—and who controls it.



Disinformation Researchers Raise Alarms About A.I. Chatbots

Researchers used ChatGPT to produce clean, convincing text that repeated conspiracy theories and misleading narratives.


How China's Government Is Using AI on Its Uighur Muslim Population



Autonomous weapons and the new laws of war

A technology that may prove hard to restrain

UNIVERSITETET
I OSLO



Verden | Kunstig intelligens

To ble drept i universitetsskyting i Florida. Skytteren fikk råd av ChatGPT før angrepet.

ChatGPT og OpenAI etterforskes etter at en student (20) skjøt og drepte to menn på Florida State University i fjor. Skytteren er halvt norsk.

Opinion **Artificial intelligence**

Trusting AI too much can turn out to be fatal

We follow faulty automated instructions because 'the computer can't be wrong'

JOHN THORNHILL

+ Add to myFT



Hvorfor etikk og samfunnskonsekvenser?

Brukeromfang

- Milliarder brukere hver dag
- Potensielle fordommer og feil kan ha store konsekvenser



Makt og rett

- Maktkonsentrasjon
- Algoritmiske beslutninger



Langsiktig samfunnspåvirkning

- Beslutninger som tas i dag kan påvirke fremtidige generasjoner



Tillit og stabilitet

- Tillit til teknologi er essensielt for demokrati



Hvorfor etikk og samfunnskonsekvenser?

- Etske handlinger er grunnleggende for **tillit**
- Vi har et **ansvar** og må vurdere konsekvensene av arbeidet vårt
- Etisk ≠ lovlig
 - Handlinger kan være lovlige men uetiske
 - Lover bør være etiske men er ikke alltid det!

Noen viktige spørsmål:

- Hvem kan ta skade?
- Kan arbeidet vårt misbrukes?



Dagens forelesning

Hva er etikk?

Etiske problemstillinger i ML-modellens livssyklus:

- utvikling
- bruk
- samfunnskonsekvenser



Hva kan vi gjøre?

Dagens forelesning

Lesestoff:

Shah kap. 13 (unntatt 13.6)

Jurafsky & Martin: kap. 7.5.2 og 7.7



Hva er etikk?

- Undergren av **filosofi**
- Læren om **moral**:
 - Hvordan man bør **handle**
 - Hvordan evaluere handlinger, personer som handler og utfall av handlinger
- Ikke en eksakt vitenskap
- Ulike filosofiske retninger vektlegger ulike prinsipper



Hva er etikk?

Flere filosofiske teorier

Konsekvensetikk (utilitarisme)

Fokus: Konsekvenser og resultater er viktigst

KI/ML: Bruk bør maksimere samfunnsnytte, minimere skade

Eksempel: Ta KI i bruk dersom nytteverdien for mange er større enn skaden for få

Utfordring: Vanskelig å forutse alle mulige konsekvenser!

Deontologisk etikk (pliktbasert)

Fokus: Regler, plikter og rettigheter står sentralt

KI/ML: Respektere menneskeverd, rett til privatliv og autonomi

Eksempel: Aldri bruk av personlige data til trening, uavhengig av konsekvens

Utfordring: Strenge regler kommer i konflikt, vanskelig å definere universelle regler

Dydsetikk

Fokus: Moralske karakter og holdninger ved beslutningstagere

KI/ML: Hva ville en god KI-utvikler gjort?

Eksempel: Utvikle med ærlighet, solidaritet, rettskaffenhet, måtehold

Utfordring: subjektive dyder, hvordan implementere algoritmisk?

Applisert etikk (f.eks. helse)


Prinsippbasert: respekt for selvbestemmelse, å gjøre godt, ikke skade, og rettferdighet

Omsorgsbasert: fokus på sosiale relasjoner og omsorg for utsatte deler av befolkningen

Evnebasert: sikre at KI bidrar til å forbedre menneskelige evner og velstand.

Etiske dilemmaer



Sporvognsproblemet (“trolley problem”)



Domenespesifikk etikk


Prinsipper:

- Rettferdighet og ikke-diskriminering
- Transparens og forklarbarhet
- Privatliv og datasikkerhet
- Sikkerhet og robusthet
- Menneskelig oversyn og kontroll



(<https://caiml.org/dighum/summerschool2024/program/prem-slides.pdf>)


Hvor skal prinsippene implementeres?



(<https://www.sciencedirect.com/science/article/pii/S266672152200028X>)

Modellutvikling

- **Data**
- Trening
- Evaluering



Data: etiske utfordringer

- **Rettigheter** (“copyright”)
 - Mye innhold på nettet er rettighetsbelagt
 - “Fair use”-doktrinen i USA
 - Juridisk utfordring
- **Privatliv** (“privacy”)
 - Data kan inneholde sensitivt innhold (IP-adresser, telefonnumre)
- **Representativitet**
 - Hvem er representert på internett? (Og dermed også i treningsdata)

Data

Authors Sue OpenAI Claiming Mass Copyright
Infringement of Hundreds of Thousands of Novels



The Times Sues OpenAI and Microsoft Over A.I. Use of Copyrighted Work

Millions of articles from The New York Times were used to train chatbots that now compete with it, the lawsuit said.



Norge og datarettigheter

- “Mimir”-prosjektet
 - Samarbeid LTG/IFI, NTNU og Nasjonalbiblioteket
 - Vurdere viktigheten av rettighetsbelagt materiale ved trening av språkmodeller
 - Forskning på datainnsamling, trening og evaluering
- Avtaler med rettighetshavere

Kulturdepartementet gir 45 millioner til ny norsk språkmodell basert på innhold fra norske aviser

[Mediepolitikk, Journalistikk](#)

Publisert 02.09.2025



Privatliv (“privacy”)

Grunnleggende menneskerett (FNs menneskerettighetserklæring)

Artikkel 12.

Ingen må utsettes for vilkårlig innblanding i privatliv, familie, hjem og korrespondanse, eller for angrep på ære og anseelse. Enhver har rett til lovens beskyttelse mot slik innblanding eller slike angrep.

Også beskyttet gjennom juridiske rammeverk som GDPR

- Regulerer behandling, lagring av **persondata** (= data tilknyttet identifiserbart individ)

Privatliv

- Personinformasjon kan ikke behandles uten lov:
 - Godkjenning fra person
 - Godkjenning må gis åpent og frivillig
- **Anonymisering** av data kan være en løsning,
 - Men ikke et trivielt problem!
- Annen mulighet: **avlæring** (“unlearning”)

Details

1 RC XXXXXX has been set up on XXX XXXX for the
XXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXXX of employees reporting to
XXXXXXXXXXXX within XXXXXXXX's Global Risk Management
organization. It will roll up under ACZStaff.0308. Please transfer
the following people from XX XXXXXX to this new RC effective
XXXXXXXXXXXXXXXX: XXXXXXXXXXX XXXXXXXXXXX XXXXXXXXXXX XXXXXXXXXXX
XXXXXXXXXXXXXXXX XXXXXXXXXXX XXXXXXXXXXXXXXXXXXX XXXXXXXXXXX If you
have any questions, please call me. If you believe anyone else
needs to receive this E-mail, please forward to the appropriate
people. Thanks. XXXXXXXXXXX x3-6343


Representasjon

- Visse **demografiske** grupper kan være **over**representert i dataset
 - andel innhold i data >> andel av befolkningen
 - F.eks. unge, hvite menn fra USA i internettdata
- **Under**representasjon av språklige og etniske minoriteter
 - Og kjønn: 16% kvinnelige redaktører i Wikipedia (og 17% av biografiene handler om kvinner)



Representasjon


- Underrepresenterte grupper i treningsdata kan oppleve dårligere ytelse fra ML-modellen
- Teknologisk ekskludering



(Konicke et al: "Racial disparities in speech recognition")

Språklig representasjon

- Kun en liten andel av verdens 7k språk er inkludert i treningsdata for språkmodeller
- Påvirker ytelsen på mindre språk (som f.eks. norsk)
 - Språk og kultur er nært forbundet
- Mange språk er ikke representert i det hele tatt!



(Joshi et. al., 2020: "The State and Fate of Linguistic Diversity and Inclusion in the NLP World.")


Skjevheter (“bias”)

«**Inclination** or **prejudice** for or against one person or group, especially in a way considered to be **unfair**»

(Oxford dictionary)

«**demographic disparities** in algorithmic systems that are **objectionable** for societal reasons»

(fairmlbook.org)



(https://navid-rekabsaz.github.io/slides/nlp/9-fairness_and_societal_biases_in_nlp.pdf)

Hvor kommer skjevhetene fra?

- Verden (**historiske** skjevheter)
 - Historisk og pågående diskriminering
- Data (**representasjonsskjevheter**)
 - Hvem er representert i dataene?
- Modeller (**aggregeringsskjevheter**)
 - Sensitiv informasjon (f.eks. etnisitet) brukes direkte/indirekte
 - Modeller mer nøyaktige for majoritetsgruppen
- Evaluering (**evalueringsskjevheter**)
 - Hva regnes som korrekt? Hvem tjener på det?
 - Skjevheter kan påvirke annotering, evaluering av systemer

Skjevheter (“bias”)

Norwegian ↔ English

Kjæresten min er lege × My boyfriend is a doctor.

[Feedback](#)

Norwegian ↔ English

Kjæresten min er sykepleier × My girlfriend is a nurse

[Feedback](#)


Hvor kommer disse skjevhetene fra?

Stemmer de egentlig for Norge?

Skjevheter (“bias”)

Beauty.AI's 'robot beauty contest' is back – and this time it promises not to be racist

The Beauty.AI robot beauty contest discriminated against dark skin. Now it's being relaunched – along with a 'Diversity AI think tank'




Sources: Bureau of Labor Statistics, American Medical Association, National Association of Women Judges, Federal Judicial Center, Bloomberg analysis of Stable Diffusion



(<https://www.bloomberg.com/graphics/2023-generative-ai-bias/>)


Modellutvikling

- Data
- **Trening**
- **Evaluering**



Skjevheter (“bias”)

- Skjevheter også i utdata fra LLMer
- ChatGPT og «delve»
- **Hva kan det skyldes?**



Skjevheter (“bias”)

LLM post-trening («alignment»)

- Utdata i tråd med brukerpreferanser
- Bruk av menneskelige tilbakemeldinger
- Utnyttelse av billig arbeidskraft i land med lave lønninger

I said “delve” was overused by ChatGPT compared to the internet at large. But there’s one part of the internet where “delve” is a much more common word: the African web. In Nigeria, “delve” is much more frequently used in business English than it is in England or the US. So the workers training their systems provided examples of input and output that used the same language, eventually ending up with an AI system that writes slightly like an African.

TechScape: How cheap, outsourced labour in Africa is shaping AI English


Workers in Africa have been exploited first by being paid a pittance to help make chatbots, then by having their own words become AI-ese. Plus, new AI gadgets are coming for your smartphones

Fjerne skjevheter? (“debiasing”)

- Pre-prosessering
 - Endring av treningsdata eller modellens input (instruksjonsjustering)
- Under trening
 - Tapsfunksjon, modellredigering (“pruning”)
- Under inferens
 - Spesialisert avkoding, f.eks. endre utdatadistribusjonen
- Post-prosessering
 - Modereringslag, vurdere om utdata er skadelig og i såfall endre/redigere

Trening

- ML-modeller optimerer en målfunksjon (“objective function”)
 - Som regel ved å minimere en tapsfunksjon
 - Klassifisering: minimere tapet mellom modellens prediksjoner og klassene i data
 - RL: maksimerer forventet belønning
- Målfunksjonen definerer hva vi ser på som korrekte utdata
- **Andre faktorer** som ikke fanges av målfunksjonen overses



Trening

Eksempel

- ML-modeller brukt i sosiale medier har som **mål** å maksimere brukerengasjement
- Kontroversielt innhold engasjerer
- Etisk problemstilling: kan føre til mer polarisering i samfunnet



Trening


Eksempel

- Personalisering av nyheter har som mål å anbefale artikler som ligner på artikler du (eller andre som ligner på deg) har lest
- «Filterboble»
- Etisk problemstilling: brukere får mindre kunnskap om ulike perspektiver



Bruk

- Etiske perspektiver på egenskaper ved modeller:
 - hallusinerer
 - sykofanti
- Uetisk bruk
 - svindel
 - desinformasjon og propaganda
- Dobbel bruk («dual use»)



Hallusinering

- LLMer trenes til å gi overbevisende svar
- I utgangspunktet ingen kobling til verden eller begrep om “sannhet”
- **Hallusinering**: usann informasjon i utdata fra LLM
 - Bedre data
 - **RAG**



➡ mindre pålitelig informasjon i det offentlige rom

Sykofanti

- Overdreven enighet, smising og skryt fra språkmodeller
- **Hvorfor er det et problem da?**



- Feilaktige ytringer fra brukere blir ikke korrigert
- Kan være særlig problematisk i bruksområder som helse og utdanning
- Språkmodeller kan bidra til å opprettholde konspirasjonsteorier og villfarelser
- Eksempler der prateroboter har støttet brukere i skadelige handlinger

Svindel

Generativ KI brukes til svindel for økonomisk vinning:

- Falsk stemme
- Falske eposter (phishing)
- Falske anmeldelser

The image shows a side-by-side comparison of two Amazon-style product reviews for headphones. The top review is from user 'mb7391' and is marked with several red 'X' icons indicating it is a fake review. The bottom review is from user 'Kiara' and is marked with green checkmark icons indicating it is a genuine review.

Review	Header	Star Rating	Text	Helpful	Verified
Fake	mb7391	5 stars	These are the greatest headphones ever!!! Super high-quality sound. You can connect without worry to your Bluetooth (including Bose SimpleSync technology). The headphones deliver up to 20 hours of wireless play, you should definitely buy one	0 people found this helpful	No
Real	Kiara	4.5 stars	These phones sound really nice, for being under \$20. They have much better sound than you might have expected at this price point. Frequency response is good for the price. Clear treble and adequate bass response to let you "feel" the drums and bass guitar. Soprano and contralto vocals sound nice and clear, without that "muddy" sound. The only caveat: the cord is only 3 feet long, not really long enough for home use with a desktop computer. Overall, though, great pair at a fair price.	89 people found this helpful	Yes

Annotations for Fake Review (mb7391):

- ✗ Few details about the reviewer
- ✗ New reviewer with only a few one-sided reviews
- ✗ Exaggerated headline
- ✗ Short, poorly written review that mentions product details
- ✗ Few or no helpful votes, not a verified purchase


Annotations for Real Review (Kiara):

- ✓ Detailed reviewer profile
- ✓ Established reviewer with many two-sided and neutral reviews
- ✓ Balanced review
- ✓ Descriptive, well-written review with subjective details
- ✓ Many helpful votes, verified purchase

(<https://www.reviewtrackers.com/blog/fake-reviews/>)

Desinformasjon & propaganda

- Generativ KI kan brukes til å spre falsk informasjon
 - «Deep fakes»
 - Falske nyheter
 - Propaganda



(https://www.youtube.com/watch?v=dHSTWepkp_M)

☰ **CNN Health** Life, But Better Fitness Food Sleep Mindfulness Relationships

Most Americans think they can spot fake news. They can't, study finds



By [Ryan Prior](#), CNN

🕒 2 min read · Updated 8:03 PM EDT, Mon May 31, 2021

Desinformasjon & propaganda

- Målrettet overtalelse ved bruk av KI til å generere tekst, bilde, video osv.
- Mål om å påvirke opinion, f.eks. ifm valg
 - Spredning av politisk innhold i sosiale medier via bot'er
 - Cambridge Analytica-skandalen
 - Nå: LLM-baserte agenter kan planlegge, tilpasse og skalere propagandakampanjer



(Newsweek: "How Big Data mines personal info to craft fake news")

Etikk og samfunnskonsekvenser

- Målrettet manipulering undergraver meningsfrihet og tillit
- Kan på sikt skade demokratiet som styreform
 - Påvirke valg
 - Økt fragmentering
 - Skjult markedsføring og svekket ansvar
- Eksempel på “dual use”: teknologi som er utviklet mtp markedsføring tas i bruk for å spre propaganda

Desinformasjon & propaganda

Kan motvirkes

- Manuell faktasjekking og kildekritikk
- Gjenkjenning av generert tekst


Faktisk.

Tenk Støtt oss Søk Meny



Artikkel

Verifisert: Amerikanske våpenrester ved barneskolen i Iran



15. april var Ukrainas president Volodymyr Zelenskyy på besøk...



Gunnar Johnsen

Journalist

Publisert: 20.04.2026 18:03 | Oppdatert: 20.04.2026 23:07

Kortversjonen

- Europa vil ta større ansvar i NATO. USA har overført ledelse av flere kommandoer til europeere.
- Tilliten til USA er svekket. Presset øker for et sterkere europeisk forsvar. Trump er uforutsigbar, sier Stortingets Peter Frølich.
- Europa mangler militær ledelse og koordinering. USA har hatt styringen. Det hevdes at en europeisk reserveplan er på trappene.


Sammendraget er laget ved hjelp av kunstig intelligens (KI) og kvalitetssikret av Aftenpostens



lister.

Faktasjekking

- Stiller krav til **lesere** →
- **Automatisert faktasjekking** er et aktivt forskningsfelt
 - Gjenkjenning av påstand
 - Kildesøk, matching og rangering
 - Verifisering av påstand




(Guo et al: "A survey on automated fact-checking")



(Fra IFLA (International Federation of Library Associations and Institutions))


Dobbel bruk (“dual use”)

- Betegner teknologi som kan brukes til både fredelige og militære formål
- Kjernekraft er et godt eksempel
 - Strømforsyning vs våpen
- **KI-systemer** har også potensiell dobbel bruk:
 - Autonome våpen, overvåking, desinformasjon
 - Viktig å være bevisst på!



Samfunnskonsekvenser

- KI som beslutningstaker
- Langsiktige konsekvenser
 - Arbeidsmarked
 - Miljø



Tillit og forklarbarhet

- Hvor mye **tillit** kan vi ha til et KI-system?
- Finne balanse mellom:
 - Ingen tillit (gjør systemet ubrukelig)
 - Overdreven tillit (og potensielt en rekke farer)
- **Forklarbarhet** er en viktig brikke i å skape tillit



NB! Se **forrige ukes forelesning** for mer om dette temaet!

KI som beslutningstaker

- KI-systemer brukes i økende grad til å ta beslutninger
- Kan vi ha **tillit** til at disse systemene tar gode beslutninger?

Automatisering av søknaden

UDI automatiserer noen av søknadene om norsk statsborgerskap. Dette betyr at saken blir vurdert av systemet for automatisk behandling. «Automatisk behandling» betyr at vi bruker informasjonen vi har om deg, og vurderer om du kan bli norsk statsborger uten at en saksbehandler ser på saken din.

Automatisk behandling av søknad

For de søknadene som blir behandlet automatisk kan du be om en manuell behandling i stedet, gi din mening, bestride eller be om innsyn i begrunnelsen for denne automatiserte avgjørelsen. Les mer i bankens [personvernerklæring](#).

MIT Technology Review

TECH POLICY

AI is sending people to jail—and getting it wrong

Using historical data to train risk assessment tools could mean that machines are copying the mistakes of the past.


By Karen Hao

January 21, 2019

KI som beslutningstaker


Eksempler:

- Behandling av lånesøknader
- Medisinsk diagnostisering og forslag til behandling
- Ansettelse: automatisk filtere og evt rangere søknader
- Autonome kjøretøy: styring/bremsing, ruteplanlegging, kollisjonsforhindring
- Innholdsmoderering, personalisering, reklame
- ...
- **Hvilke beslutninger er best fra et etisk perspektiv?**
- **Hvordan kan vi forsikre oss om at KI-systemer handler i tråd med etiske verdier og menneskelige intensjoner? (“alignment”-problemet)**




“Moral machine”

- Nettplattform for å innhente etiske vurderinger fra mennesker over hele verden
- Basert på det klassiske sporvognsproblemet fra etisk teori, men tilpasset **autonome kjøretøy**
- Deltakere presentert for ulike **kollisjonsscenarioer**:
 - Svinge eller la være
 - Ulike potensielle ofre: fotgjengere, passasjerer, barn, gamle, dyr, lovlydige vs mennesker som bryter trafikkregler osv.



Show Description



Show Description


(<https://www.moralmachine.net/>)

“Moral machine”

Mål: Studere etiske vurderinger i befolkningen, på tvers av kulturer

Funn:

- Ingen universelle moralske regler, variasjon på tvers av kulturer
- Noen mønstre:
 - Redde flere liv foretrekkes
 - Redde unge framfor gamle, og lovlige, mennesker framfor dyr




KI som beslutningstaker

Automatisert retting

- Tas i bruk allerede, særlig i nettbasert undervisning
- Trenes på historiske eksempler på eksamener og tilbakemeldinger
- Ulike bruksområder:
 - Underveis-vurdering
 - Eksamensretting
 - Karakterbegrunnelser

Can A.I. Grade Your Next Test?

Neural networks could give online education a boost by providing automated feedback to students.



Juan Bernabeu



By Cade Metz

Automatisert retting

I Norge:

Utvalget for KI i høyere utdanning (“Malthe-Sørensen-utvalget”) med rapport:

<https://malthesorensenutvalget.no/notat-forelopige-vurderinger/>


Anbefalinger:

- Færre ikke-kontrollerte eksamensformer
- Universiteter bør gjennomføre kontrollerte forsøk med KI-systemer til **sensur**
- Universiteter bør gjennomføre kontrollerte forsøk med KI-systemer automatiserte **karakterbegrunnelser**

Arbeidsmarked

- Hvordan kommer KI-bruk til å påvirke framtidens arbeidsmarked?
- Rapport fra Anthropic (2026)
 - Teoretisk potensiale
 - Faktisk bruk
- Effekten størst i «kunnskapsyrker», yrker som kan automatiseres helt eller delvis av KI

Theoretical capability and observed usage by occupational category



(<https://www.anthropic.com/research/labor-market-impacts>)

Hva med Norge?

Kronikk →

Vi utdanner til arbeidsledighet takket være KI

Tusenvís av studenter står nå forventningsfulle og klare til å ta fatt på et nytt studieløp i august. De har flere veldig givende, men krevende, studieår foran seg.

Annonseinnhold fra tredjepart [gens](#)

Norges Bank: Disse jobbene forsvinner på grunn av KI

KI i arbeidslivet: – Du utkonkurreres ikke av kunstig intelligens i seg selv. Du utkonkurreres av noen som kan bruke det bedre enn deg

Hva med Norge?


Kompetansebehovsutvalget (2024-25):

- Økt behov for digital kompetanse
- Endret, ikke bare erstattet
- Behov for akademisk kompetanse: kritisk tenkning, høyere utdanning
- Utfordringer:
 - Utenforskap
 - Svekket læring
 - Datakontroll



Temarapport 2025

Framtidige kompetansebehov:
Hvilken kompetanse trenger Norge
for å lykkes med digital omstilling?



Hva med Norge?

SAMORDNA OPPTAK

Oppfordrer til IT-studier. — Vi trenger at folk velger teknologi

Forsknings- og høyere utdanningsminister Sigrun Aasland oppfordrer kommende studenter til å søke IT-studier, og sier det fremdeles er et trygt studievalg med jobbutsikter.



SØKERTALL

Fortsatt nedgang i søkere til it-studier

Også i år faller søkningen til studier i informasjonsteknologi, men fallet er langt mindre enn i fjor.

UNIVERSITETET
I OSLO



Miljø


Trening av store
språkmodeller er enormt
ressurskrevende

- Spesialisert maskinvare (GPUer)
- Stort **strømforbruk**
- Datasentre med (ti-hundre)tusenvis av GPUer

PRESSEMELDING - 1. APRIL 2025 07:11 ↗ Dele

Norges kraftigste superdatamaskin har ankommet Nordfjordeid

Norges kraftigste superdatamaskin noensinne, Olivia, har nå ankommet Nordfjordeid. Installasjonsfasen starter umiddelbart, etterfulgt av en testfase før norske forskere får tilgang til den teknologiske giganten.



Modelltrening har et betydelig karbonavtrykk



CO2 Equivalent Emissions (Tonnes) by Selected Machine Learning Models and Real Life Examples, 2022

Source: Luccioni et al., 2022; Strubell et al., 2019 | Chart: 2023 AI Index Report





Figure 2.8.2

Miljø

Bruk av modeller (såkalt “inferens”)


- 90% av energiforbruk i mange modellers livssyklus
- Trening gjøres kun én gang mens inferens er pågående



Miljø

Fokus på **energieffektive** metoder for trening og inferens

- Data: **kvalitet** framfor kvantitet, bedre utnyttelse av data (pensumlæring “curriculum learning”)
- Mer effektive arkitekturer
- **Mindre** modeller (distillering, kvantisering)
- Energieffektive datasentre
- **Gjenbruk**
 - Krever åpne modeller




Hva kan vi gjøre da?

- Etikk i praksis
- Dokumentasjon
- “ML for good”
- Regulering

Etikk i praksis

Hvem har ansvaret?



Modellutviklere


Tilbydere, produkteiere,
konsumenter

Myndigheter

Modellutviklere


Ansvarlig utvikling:

- Bevissthet rundt risiko og potensiell skade, prioritere sikkerhet framfor fart
- Respekt for rettigheter: privatliv, lisenser, dataeierskap
- Transparens: **dokumentasjon** (data/modellkort) og **evaluering**



Modellutviklere


- Økt bevissthet rundt **hvilke** applikasjoner vi fokuserer på
- ML/KI kan bidra til å nå FNs bærekraftsmål
 - Helse
 - Utdanning
 - Fredsbevaring
 - Klima
 - Inkludering



("NLP for social good": <https://arxiv.org/abs/2505.22327>)

Regulering: EUs KI-forordning

- **Risiko**-basert rammeverk for å regulere KI-bruk i EU
- Ulike forpliktelser avhengig av kategori
- Høyrisiko:
 - Dokumentasjon
 - Datakvalitet
 - Nøyaktighet, sikkerhet
 - Loggføring
 - Klare brukerinstruksjoner



Det var det!



Veien mot eksamen 8 juni

Prøveeksamen

⇒ tilgjengelig fra 6 mai

Siste forelesning 20 mai: gjennomgang av prøveeksamen

Repetisjonsgrupper

- Hver gruppe tar for seg ett tema
- NB! De tre siste forelesningene er også pensum
- Gruppene er for alle!

- ✓ Trekk, vektorer og vektorrom
Matematisk grunnlag
- ✓ Klassifikasjon og klynging +
Beslutningstrær
- ✓ Lineær og logistisk regresjon
- ✓ Nevrale nettverk
- ✓ Forsterkende læring